

BÀI GIẢNG CHUYÊN ĐỀ DÀNH CHO NGƯỜI MỚI BẮT ĐẦU (TỪ CON SỐ 0)

LÀM THẾ NÀO MÁY TÍNH HIỂU ĐƯỢC NGÔN NGỮ CON NGƯỜI?

Khám phá Từ Vector Hóa Word2Vec, Mạng Nơ-ron Chuỗi LSTM đến Cơ Chế Attention

Thông Tin Học Phần & Đơn Vị

Học phần: Xử lý ngôn ngữ tự nhiên (NLP)

Đơn vị: Trường ĐH Sư phạm TP.HCM (HCMUE)

Giảng viên hướng dẫn: PGS.TS. LÊ ANH CƯỜNG

Mục tiêu: Dễ hiểu, trực quan, giải thích bản chất cốt lõi

Người Trình Bày (Nhóm 3 Học Viên)

1. Trần Gia Huy — MSHV: KHMT836012

2. Đỗ Minh Khánh Ngân — MSHV: KHMT836019

3. Nguyễn Tấn Phát — MSHV: KHMT836026

Thực hành tương tác: <http://localhost:8501>

Lộ Trình Khám Phá: 6 Nấc Thang Nhận Thức

- ❶ **Câu hỏi khởi đầu:** Tại sao máy tính không đọc được chữ?
- ❷ **Cách làm cổ điển:** One-Hot và Đếm từ (BoW / TF-IDF) gặp cạm bẫy gì?
- ❸ **Cuộc cách mạng Word2Vec:** Khi từ ngữ trở thành các tọa độ hình học trong không gian.
- ❹ **Từ từ đơn đến cả câu:** Tại sao phép cộng trung bình bị hỏng bởi chữ "*không*"?
- ❺ **Mạng nơ-ron LSTM:** Ba lô trí nhớ thông minh biết quên chuyện cũ, nạp chuyện mới.
- ❻ **Cơ chế Attention:** Cây bút dạ quang giúp AI biết từ nào là chìa khóa cảm xúc.

Phương châm bài giảng

Không lạm dụng công thức phức tạp — Tập trung vào trực giác toán học, ví dụ đời thực và ứng dụng!

1. Câu Hỏi Khởi Đầu: Tại Sao Máy Tính Không Đọc Được Chữ?

Thực tế về máy tính

- Máy tính chỉ biết tính toán trên **con số thực** (cộng, trừ, nhân ma trận).
- Đối với máy tính, câu "*Trường Sư Phạm rất đẹp*" chỉ là một mớ ký tự vô tri gồm các mã ASCII/Unicode nhị phân (010101...).
- Máy tính không có khái niệm trực giác thể nào là "*đẹp*", thể nào là "*xấu*".

Mục tiêu của NLP (Biểu diễn từ)

Tìm một chiếc **cầu nối toán học** để biến mỗi từ ngữ thành một dãy số (vector) sao cho: *Các từ có nghĩa tương tự nhau sẽ có các con số gần nhau!*

Cách tiếp cận ngây thơ: Đánh số thứ tự (ID)

Giả sử ta đánh số từ điển theo thứ tự:

- $con_mèo = 1$
- $con_chó = 2$
- $xe_tải = 3$

Cạm bẫy toán học xuất hiện:

- Máy tính hiểu: $1 + 2 = 3 \implies Mèo + Chó = Xe tải (!)$
- Khoảng cách giữa *Mèo* và *Xe tải* ($3 - 1 = 2$) lại lớn hơn khoảng cách *Mèo* và *Chó* ($2 - 1 = 1$). Nếu đánh số ngẫu nhiên, trật tự này hoàn toàn sai lệch!

$\implies$ **Đánh số đơn thuần là ngớ cụt!**

2. Cách Làm Cổ Điển: Mã Hóa One-Hot Có Tốt Không?

Ý tưởng One-Hot Encoding

Nếu từ điển có $|V|$ từ, mỗi từ là một dãy có độ dài $|V|$ với đúng một số 1 ở vị trí của nó:

$$\text{giảng_viên} = [1, 0, 0, 0, \dots, 0]^T$$

$$\text{thầy_cô} = [0, 1, 0, 0, \dots, 0]^T$$

$$\text{xe_máy} = [0, 0, 1, 0, \dots, 0]^T$$

- **Ưu điểm:** Không còn phép cộng vô lý như đánh số 1, 2, 3.

3 Căn bệnh nghiêm trọng của One-Hot

- ❶ **Khổng lồ và lãng phí bộ nhớ:** Từ điển tiếng Việt có 50,000 từ $\rightarrow$ Mỗi từ là vector 50,000 chiều toàn số 0.
- ❷ **Căn bệnh "Mù ngữ nghĩa" (Tính trực giao):**

$$\mathbf{v}_{\text{giảng_viên}} \cdot \mathbf{v}_{\text{thầy_cô}} = 0$$

$$\mathbf{v}_{\text{giảng_viên}} \cdot \mathbf{v}_{\text{xe_máy}} = 0$$

Máy tính thấy "*giảng viên*" xa lạ với "*thầy cô*" y hệt như với "*xe máy*"!

- ❸ Không thể đo được độ đồng nghĩa hay trái nghĩa.

Đếm Từ Thông Minh Hơn: TF-IDF (Tần Suất & Nghịch Đảo)

Nguyên lý trực giác của TF-IDF

- **TF (Term Frequency):** Từ nào xuất hiện nhiều trong câu đó thì từ đó quan trọng với câu đó.
- **IDF (Inverse Document Frequency):** Từ nào câu nào cũng có (như *và, thì, là, của, những*) thì từ đó là **từ rác**, cần bị phạt điểm nặng!

Điểm số = Tần suất trong bài $\times$ Độ quý hiếm

Hạn chế cốt tử: Bỏ quên trật tự từ (Bag-of-Words)

Vì chỉ gom từ vào một cái "túi" để đếm số lượng, TF-IDF hoàn toàn không hiểu thứ tự:

- Câu A: "*Thầy dạy không khó hiểu chút nào.*" $\rightarrow$ Khen (Tích cực).
- Câu B: "*Thầy dạy khó hiểu, không thích.*" $\rightarrow$ Chê (Tiêu cực).

Cả hai câu đều chứa các từ giống hệt nhau $\Rightarrow$ **TF-IDF cho ra hai vector gần như trùng nhau!**

3. Cuộc Cách Mạng Word2Vec: Từ Ngữ Thành Tọa Độ Không Gian

Ý tưởng thiên tài của Tomas Mikolov (2013)

Dựa trên triết lý ngôn ngữ học của J.R. Firth (1957):

"Hãy cho tôi biết bạn bè xung quanh bạn, tôi sẽ nói bạn là ai!"

- Thay vì dùng vector 50,000 chiều thừa thớt, ta nén mỗi từ thành một vector nhỏ gồm **100 con số thực dày đặc** ($\mathbb{R}^{100}$).
- 100 con số này đóng vai trò như **tọa độ GPS** trên một bản đồ ngữ nghĩa đa chiều.

Phép toán vector kỳ diệu

Trong không gian Word2Vec, khoảng cách hình học phản ánh quan hệ đời thực:

$$v_{\text{Vua}} - v_{\text{Đàn_ông}} + v_{\text{Phụ_nữ}} \approx v_{\text{Nữ_hoàng}}$$

$$v_{\text{Hà_Nội}} - v_{\text{Việt_Nam}} + v_{\text{Pháp}} \approx v_{\text{Paris}}$$

- *Từ đồng nghĩa: thầy và giảng viên* nằm sát cạnh nhau.
- Góc Cosine giữa chúng tiến gần về 1.0!

Word2Vec Học Như Thế Nào? Hai Trò Chơi Đoán Chữ

Trò chơi 1: CBOW (Đoán từ ở giữa)

- Nhìn vào các từ hàng xóm xung quanh để đoán từ trung tâm bị che mất.

Hôm nay trời [?] và có nắng nhẹ → Mô hình đoán chữ:

đẹp / ấm.

→ Thích hợp học các từ thông dụng, tốc độ huấn luyện rất nhanh.

Trò chơi 2: Skip-Gram (Đoán các từ bạn bè)

- Cho một từ trung tâm duy nhất, bắt mô hình đoán các từ thường đi cùng nó.

Từ trung tâm: **giảng_viên** → Mô hình đoán quanh đó có:

nhiệt_tình, bài_tập, slide, điểm.

→ Cực kỳ xuất sắc trong việc học các **từ hiếm gặp**.

Bí quyết tốc độ: Negative Sampling (SGNS)

Thay vì bắt máy tính so sánh với toàn bộ 50,000 từ trong từ điển (rất chậm), ta chỉ bắt nó phân biệt từ đúng với **5 từ ngẫu nhiên chọn bừa** (mẫu âm). Máy tính học nhanh hơn hàng trăm lần!

4. Từ Vector Từng Từ Đến Cả Câu: Cạm Bẫy Cộng Trung Bình

Cách làm đơn giản nhất: Average Word2Vec

Lấy các vector của từng từ trong câu rồi tính **trung bình cộng** lại để thành 1 vector đại diện câu:

$$v_{\text{câu}} = \frac{1}{N}(v_{w_1} + v_{w_2} + \dots + v_{w_N})$$

- Dễ cài đặt, chạy cực nhanh, không cần huấn luyện thêm.
- Nhưng tại sao trong thực nghiệm, nó lại cho kết quả kém hơn cả TF-IDF?

Cạm bẫy: Nghịch lý triệt tiêu phủ định

- 1 **Phép cộng có tính giao hoán:** $A + B = B + A$. Câu đảo ngược thứ tự từ vẫn sinh ra vector y hệt nhau!
- 2 **Chữ "KHÔNG" bị hòa tan:**
 - Từ "*không*" xuất hiện ở mọi nơi, cạnh cả từ khen lẫn chê → Vector của nó nằm ở chính giữa trung tâm không gian.
 - Khi lấy $v_{\text{tốt}} + v_{\text{không}}$, vector kết quả chỉ hơi lệch một chút so với "*tốt*".
 - Phép cộng chỉ **pha loãng** chứ không thể **lật ngược 180 độ** cực tính từ Tích cực sang Tiêu cực!

⇒ **Cần một mô hình biết đọc tuần tự theo thời gian!**

5. Mạng Nơ-ron Hồi Quy LSTM: Chiếc Ba Lô Trí Nhớ Thông Minh

Con người đọc câu như thế nào?

Chúng ta đọc từng từ một từ trái sang phải. Khi đọc đến từ thứ 5, trong đầu ta vẫn còn lưu giữ thông tin của 4 từ trước đó.

→ Mạng RNN/LSTM mô phỏng chính xác quá trình này qua

Trạng thái ẩn (Hidden state h_t) và **Ô nhớ dài hạn (c_t)**.

Tại sao RNN thường bị "đãng trí"?

RNN đơn giản bị hiện tượng tiêu biến gradient (*Vanishing Gradient*): Câu dài trên 10 từ là nó quên sạch những gì đã đọc ở đầu câu!

Giải pháp của LSTM: 3 Cổng gác thông minh

LSTM như một người đi du lịch mang theo chiếc ba lô:

- 1 **Cổng quên (Forget Gate):** Bỏ bớt rác cũ trong ba lô không còn dùng đến.
- 2 **Cổng nạp (Input Gate):** Chọn lọc những món đồ mới có giá trị nhét vào ba lô.
- 3 **Cổng ra (Output Gate):** Quyết định từ những thứ trong ba lô, hiện tại nên nói ra điều gì.

⇒ **LSTM có thể nhớ ngữ cảnh cách xa hàng chục từ mà không bị quên!**

Mạng BiLSTM: Đọc Xuôi & Đọc Ngược Cùng Lúc

Tại sao một chiều là chưa đủ?

Hãy thử đoán nghĩa từ **"độ"** trong câu:

"Chiếc xe này đã được độ ..."

- Nếu chỉ đọc từ trái sang phải, ta chưa rõ là *độ* xe hay *nhiệt độ*.
- Nhưng nếu đọc tiếp phần sau: *"... lên công suất 150 mã lực"*, ta hiểu ngay ngữ cảnh!

BiLSTM (Bidirectional LSTM)

Chạy 2 mạng song song:

- Một mạng đọc từ trái sang phải ($w_1 \rightarrow w_T$).
- Một mạng đọc từ phải sang trái ($w_T \rightarrow w_1$).
- Ghép hai góc nhìn lại: $h_t = [\vec{h}_t; \overleftarrow{h}_t] \rightarrow$ Hiểu trọn vẹn ngữ cảnh hai phía.

Nhưng vẫn còn 1 điểm yếu: Nghẽn cổ chai (Bottleneck)

BiLSTM truyền thông gom toàn bộ câu thành vector bước cuối cùng h_T .

Hậu quả: Giống như bắt bạn đọc cuốn sách 20 trang rồi chỉ được viết đúng 1 dòng tóm tắt. Rất nhiều thông tin chi tiết quý giá ở giữa câu bị rơi rụng!

$\Rightarrow$ **Làm sao để không bỏ sót bất kỳ từ nào?**

6. Cơ Chế Chú Ý (Attention Mechanism): Cây Bút Dạ Quang

Ảnh dụ đời thực

Khi đọc một câu nhận xét:

"Thầy giảng dạy rất nhiệt tình và bài tập dễ hiểu."

Bộ não chúng ta không ghi nhớ đồng đều từng chữ. Chúng ta cảm một cây **bút dạ quang** tô sáng vào hai từ: **nhiệt tình** và **dễ hiểu**!


Toán học hóa cây bút dạ quang

Cơ chế Attention tính cho mỗi từ một trọng số $\alpha_t \in [0, 1]$ (tổng các $\alpha = 100\%$):

$$v_{\text{toàn câu}} = \sum_{t=1}^T \alpha_t h_t$$

Từ nào mang cảm xúc mạnh $\rightarrow$ nhận α_t lớn!

Bản đồ nhiệt Attention trong thực tế



Hình: Mô hình tự động dồn trọng số vào từ quyết định.

Explainable AI (Khả năng giải thích)

Mô hình không còn là chiếc hộp đen bí ẩn. Nhìn vào trọng số α_t , con người biết chính xác **vì sao máy tính lại dự đoán là Tích cực hay Tiêu cực!**

7. Bước Nhảy Vọt Lên Transformer & PhoBERT Tiếng Việt SOTA

Giới hạn của Word2Vec tĩnh

Word2Vec gán mỗi từ đúng 1 vector cố định:

- "Tôi uống nước cam" (chất lỏng).
- "Bảo vệ đất nước" (quốc gia).

Cả hai từ "nước" trên đều bị ép chung một tọa độ vector $\Rightarrow$
Không chuẩn xác!

Cuộc cách mạng Contextual Embedding

Mô hình **PhoBERT (VinAI, 2020)** dựa trên Transformer:

- Huấn luyện trên **20GB báo chí tiếng Việt** (3 tỷ từ).
- Vector của một từ được sinh ra **động** tùy theo ngữ cảnh của câu cụ thể.
- Đọc hiểu cấu trúc câu phức tạp và ẩn ý sâu sắc.

Bí kíp trị Teencode: Tokenizer BPE

Khi gặp từ lóng hoặc viết tắt trên mạng:

- Word2Vec tĩnh: Bó tay, gán thành từ rác UNK (Unknown).
- **PhoBERT (Byte-Pair Encoding)**: Tự động bẻ nhỏ từ lạ thành các mảnh âm tiết quen thuộc để suy luận.

$\Rightarrow$ Giúp PhoBERT đạt độ bền bỉ vượt trội trước ngôn ngữ mạng xã hội đầy nhiễu!

8. Thực Chiến: Bài Toán Phân Loại Cảm Xúc (Sentiment Analysis)

Để kiểm chứng các mô hình trên đời thực, nhóm tiến hành thử nghiệm trên **3 miền dữ liệu độc lập**:

Đặc điểm	Miền 1: Giáo Dục (UIT-VSFC)	Miền 2: Mua Sắm (E-Commerce)	Miền 3: Điện Ảnh (Review Phim)
Nội dung	Khảo sát ý kiến sinh viên về giảng viên	Đánh giá chất lượng sản phẩm	Đánh giá diễn xuất, kịch bản phim
Phong cách	Lịch sự, câu cú chuẩn ngữ pháp	Tiếng lóng, viết tắt, teencode (<i>sp, ship, auth</i>)	Câu ghép dài, nhiều tương phản
Độ khó	Trung bình (Dễ bắt từ khóa)	Rất cao (Nhiều nhiễu, lỗi chính tả, mỉa mai)	Cao (Khen diễn viên nhưng chê kịch bản)

Đầu vào (Input)

Một đoạn văn bản nhận xét của người dùng.

Đầu ra (Output)

Xác suất nhãn: **TÍCH CỰC** hay **TIÊU CỰC**.

Bảng Đối Chuẩn Kết Quả: Ai Thắng Ai?

Kết quả thực nghiệm trên tập kiểm thử độc lập của 3 miền:

Cấp độ	Kiến trúc Mô hình	Giáo dục (UIT-VSFC)	TMDT (E-Commerce)	Review Phim (IMDb)
Cổ điển	1. TF-IDF + Logistic Regression	89.83%	70.33%	89.20%
Nhúng tĩnh	2. Average Word2Vec + Logistic Regression	87.50%	67.33%	86.40%
Chuỗi RNN	3. BiLSTM Classifier (Học từ đầu)	89.17%	69.17%	88.10%
Học chuyển giao	4. BiLSTM Pretrained Word2Vec	91.00%	67.17%	90.80%
Cơ chế Chú ý	5. BiLSTM + Self-Attention (Đề xuất XAI)	91.83%	72.50%	92.40%
Transformer SOTA	6. PhoBERT Base v2 (VinAI)	95.50%	86.17%	94.80%

Quan sát 1: Attention tạo bất phá


Tăng tới +5.33% trên miền TMDT nhờ khả năng lọc bỏ từ rác và bắt trúng từ cảm xúc.

Quan sát 2: PhoBERT dẫn đầu toàn diện

Đạt đỉnh 95.50% trên giáo dục và bền bỉ vượt trội trước tiếng lóng TMDT (86.17%).

Khám Phá Trực Quan: Các Điểm Dữ Liệu Gom Nhóm Như Thế Nào?


t-SNE Average Word2Vec (UIT-VSFC)



1. Average Word2Vec

Điểm đỏ (Neg) và xanh (Pos) dính chùm, ranh giới mờ nhạt.


t-SNE BiLSTM Representation (UIT-VSFC)



2. BiLSTM Representation

Bắt đầu tách thành 2 nhánh rõ ràng nhờ học chuỗi.

t-SNE PhoBERT Contextual Embeddings (UIT-VSFC)



3. PhoBERT Contextual

Tách biệt tuyệt đối thành 2 khối tách rời nhau!

Ý nghĩa trực quan

Mô hình càng xịn thì không gian biểu diễn càng tách bạch rõ ràng giữa **Vui (Tích cực)** và **Buồn (Tiêu cực)**, giúp việc kẻ một đường phân cách trở nên dễ dàng và chuẩn xác!

Các Ca Khó Kinh Điển Trong Đời Thực Khiến AI Bối Rối

Ca khó 1: Cấu trúc câu tương phản lật ngược tình thế

- "*Giao hàng hơi lâu nhưng chất lượng áo thì đỉnh chóp.*" → **Thực tế: TÍCH CỰC.**
- **Mô hình đơn giản:** Thấy chữ "*hơi lâu*" ở đầu câu nên vội vã kết luận Tiêu cực.
- **Cơ chế Attention / PhoBERT:** Hiểu được từ "*nhưng*" đóng vai trò bản lề, dồn toàn bộ sự chú ý vào vế sau "*chất lượng đỉnh chóp*" để đoán đúng Tích cực!

Ca khó 2: Ngôn ngữ mỉa mai, châm biếm (Sarcasm) — Giới hạn của AI hiện nay

- "*Shop phục vụ quá nhiệt tình, nhấn tin 3 ngày mới thêm trả lời.*" → **Thực tế: TIÊU CỰC.**
- **AI hiện nay đều sai:** Nhìn thấy từ "*quá nhiệt tình*" liền mừng rỡ đoán Tích cực!
- **Vì sao AI bị lừa?:** AI chưa có tri thức đời thực (*World Knowledge*) để hiểu rằng chờ đợi 3 ngày là điều bực mình. Đây là bài toán mở đầy hấp dẫn của NLP tương lai!

9. Trải Nghiệm Thực Tế Hệ Thống Web Demo


Học đi đôi với hành (Interactive Demo)

Nhóm đã xây dựng sẵn một ứng dụng Web trực quan:

- **Gõ câu bất kỳ:** Tiếng Việt hoặc tiếng Anh, có teencode, viết tắt.
- **So sánh 6 mô hình cùng lúc:** Xem mô hình nào đoán đúng, mô hình nào bị lừa.
- **Xem bản đồ nhiệt Attention:** Rê chuột xem trọng số α_t của từng từ.

Khởi chạy đơn giản với 1 câu lệnh

```
cd Bai_tap_giua_ky && ./run_app.sh
```



Hình: Giao diện trực quan hoá 6 mô hình đối đầu.

Tổng Kết: 5 Bài Học Cốt Lõi Cho Người Mới Bắt Đầu

1. Biểu diễn từ là nền tảng

Không có vector chất lượng, không mô hình học sâu nào hoạt động tốt. Từ One-Hot rời rạc → Word2Vec liên tục là bước ngoặt vĩ đại của NLP.

2. Trật tự câu quyết định ý nghĩa

Đừng chỉ cộng trung bình các từ. Hãy dùng mạng xử lý chuỗi như **LSTM/BiLSTM** để giữ trọn ngữ cảnh xuôi - ngược.

3. Cơ chế Chú ý mở toang hộp đen

Self-Attention không chỉ tăng độ chính xác mà còn cho ta biết lý do tại sao AI đưa ra quyết định đó (**Explainable AI**).

4. Transformer là tương lai

Các mô hình tiền huấn luyện lớn như **PhoBERT** giải quyết bài toán đa nghĩa và bền bỉ trước tiếng lóng nhờ cơ chế Tokenizer BPE.

5. Hiểu dữ liệu quan trọng hơn chỉnh mô hình

Mô hình đạt 95% ở miền giáo dục có thể tụt xuống 72% ở miền TMDT nếu không hiểu về sự dịch chuyển phân phối (**Domain Gap**).



TRƯỜNG ĐẠI HỌC SƯ PHẠM TP. HỒ CHÍ MINH

KHOA CÔNG NGHỆ THÔNG TIN — LỚP CAO HỌC KHMT K36

CẢM ƠN CÁC BẠN ĐÃ THEO DÕI BÀI GIẢNG!
CHÚC CÁC BẠN CHINH PHỤC THÀNH CÔNG NLP!

Giảng viên hướng dẫn: PGS.TS. LÊ ANH CƯỜNG

Nhóm 3: Trần Gia Huy • Đỗ Minh Khánh Ngân • Nguyễn Tấn Phát

GÓC THẢO LUẬN & GIẢI ĐÁP THẮC MẮC (Q&A)

Mã nguồn bài học & Web Demo: <https://github.com/trangiahuy8444/NLP>