



BÁO CÁO TIỂU LUẬN GIỮA KỲ — HỌC PHẦN XỬ LÝ NGÔN NGỮ TỰ NHIÊN

MÔ HÌNH WORD2VEC, WORD EMBEDDING VÀ HỌC BIỂU DIỄN VĂN BẢN BẰNG LSTM CHO BÀI TOÁN PHÂN LOẠI CẢM XÚC

Nghiên cứu lý thuyết, Hiện thực mô hình, Đối chuẩn Đa miền & Triển khai Ứng dụng XAI

Thông Tin Học Phần & Giảng Viên

Đơn vị: ĐH Sư phạm TP.HCM (HCMUE) — Khoa CNTT

Chuyên ngành: Cao học Khoa học Máy tính (K36)

Giảng viên hướng dẫn: **PGS.TS. LÊ ANH CƯỜNG**

Thời gian: Tháng 10/2026

Học Viên Thực Hiện (Nhóm 3)

1. Trần Gia Huy — MSHV: KHMT836012

2. Đỗ Minh Khánh Ngân — MSHV: KHMT836019

3. Nguyễn Tân Phát — MSHV: KHMT836026

Hệ thống Web Demo: <http://localhost:8501>

Nội Dung Báo Cáo

1 Đặt Vấn Đề & Mục Tiêu Nghiên Cứu

- Thách thức biểu diễn ngữ nghĩa tiếng Việt
- 7 đóng góp trọng tâm của nhóm học viên

2 Cơ Sở Lý Thuyết & Kiến Trúc

- Không gian vector Word2Vec (CBOW, Skip-Gram, SGNS)
- Học biểu diễn chuỗi bằng BiLSTM
- Cơ chế Chú ý Additive Self-Attention & XAI
- Mô hình ngôn ngữ ngữ cảnh SOTA: PhoBERT

3 Thiết Kế Thực Nghiệm & Đa Miền

- 3 miền ngữ liệu: UIT-VSFC, E-Commerce, Review-Phim
- Quy trình tiền xử lý 5 bước chuẩn hóa

4 Kết Quả Đối Chuẩn & Đánh Giá

- Bảng đối chuẩn toàn diện 6 mô hình trên 3 miền
- Giải thích quyết định qua Attention Heatmap (XAI)
- Tiến hóa không gian biểu diễn văn bản qua t-SNE
- Thảo luận 4 luận điểm học thuật then chốt
- Phân tích lỗi định tính (Qualitative Error Analysis)

5 Sản Phẩm Ứng Dụng Thời Gian Thực

- Kiến trúc suy luận song song 6 mô hình
- Trải nghiệm Web Demo tương tác trực quan

6 Kết Luận & Hướng Phát Triển

1. Đặt Vấn Đề: Thách Thức Biểu Diễn Ngữ Nghĩa Tiếng Việt

Thách thức cốt lõi của bài toán Biểu diễn từ

- Làm sao ánh xạ ngôn ngữ rời rạc thành vector dày đặc $\mathbb{R}^d$ giữ trọn **khoảng cách ngữ nghĩa**?
- **Đặc thù tiếng Việt**: Ngôn ngữ đơn lập, không biến hình từ, ranh giới từ phức tạp (*từ ghép, từ láy, thành ngữ*).
- Hiện tượng đa nghĩa, đảo ngữ, cấu trúc phủ định và sắc thái châm biếm (*sarcasm*).

Giả thuyết phân bố (Distributional Hypothesis - Firth, 1957)

"You shall know a word by the company it keeps"

(Một từ vựng được định nghĩa bởi tập hợp các từ xuất hiện quanh nó)

Hạn chế của mô hình cổ điển (One-Hot, TF-IDF)

- **Bùng nổ số chiều**: Kích thước ma trận bằng $|V|$ ($10^4 - 10^5$), cực kỳ lãng phí bộ nhớ.
- **Tính trực giao tuyệt đối**: $e_i^T e_j = 0, \forall i \neq j$. Không đo được sự tương đồng giữa *"giảng viên"* và *"thầy cô"*.
- **Mất trật tự từ (Bag-of-Words)**: Bỏ qua hoàn toàn cú pháp và phụ thuộc ngữ cảnh dài hạn.

Mục Tiêu Nghiên Cứu & 7 Đóng Góp Chính Của Đề Tài


1. Nghiên Cứu Lý Thuyết & Mô Hình Hóa

- **Làm chủ chuỗi biểu diễn:** Khảo sát hệ thống từ One-Hot, TF-IDF, Word2Vec (*CBOW*, *SGNS*) đến BiLSTM và PhoBERT SOTA.
- **Mô hình hóa chuỗi với BiLSTM:** Trích xuất vector biểu diễn câu v_D bất trộn ngữ cảnh xuôi - ngược.
- **Đề xuất Additive Self-Attention:** Giải quyết triệt để **nghẽn cổ chai thông tin** của LSTM, tăng độ chính xác và cung cấp khả năng giải thích quyết định (**XAI**).

2. Thực Nghiệm Đa Miền & Triển Khai Thực Tế

- **Đôi chuẩn đa miền (Cross-Domain):** Kiểm thử độc lập trên 3 miền: Giáo dục (**UIT-VSFC**), Thương mại (**E-Commerce**) và Điện ảnh (**IMDb**).
- **So sánh 6 mô hình song song:** Phân tích định lượng lẫn định tính nguyên nhân dịch chuyển phân phối dữ liệu (*Domain Gap*).
- **Trực quan hóa t-SNE & Heatmap:** Minh chứng quá trình tiến hóa hình học không gian vector.
- **Ứng dụng Web Demo tương tác:** Xây dựng giao diện suy luận thời gian thực hoàn chỉnh.

2. Tiến Trình Phát Triển Biểu Diễn Từ Trong NLP



Biểu Diễn Tĩnh (Static Embeddings)

- **Word2Vec, FastText, GloVe:** Mỗi từ gán cố định một vector duy nhất trong không gian $\mathbb{R}^d$.
- **Hạn chế:** Từ đa nghĩa ("nước suối" vs "đất nước") dùng chung 1 vector; không xét ngữ cảnh cụ thể trong câu.

Biểu Diễn Động Theo Ngữ Cảnh (Contextual)

- **BiLSTM, Transformer, PhoBERT:** Vector của từ phụ thuộc hoàn toàn vào các từ đứng trước và sau nó.
- **Ưu thế vượt trội:** Giải quyết triệt để đa nghĩa, đảo ngữ, phụ thuộc xa (*Long-range dependencies*).

Không Gian Vector Phân Bố Word2Vec: CBOW, Skip-Gram & SGNS

CBOW vs Skip-Gram

CBOW: Dự đoán từ trung tâm w_t từ ngữ cảnh xung quanh:

$$\mathcal{L}_{\text{CBOW}} = \sum_{t=1}^T \log P(w_t \mid w_{t-c}, \dots, w_{t+c})$$

Skip-Gram: Từ từ trung tâm, dự đoán ngữ cảnh:

$$\mathcal{L}_{\text{SG}} = \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log P(w_{t+j} \mid w_t)$$

Skip-Gram học từ hiếm và ngữ nghĩa đa dạng rất tốt.

Tối ưu hóa: Negative Sampling (SGNS)

Vấn đề Softmax: Mẫu số $\sum_{w' \in V} \exp(v_{w'}^T v_w)$ tiêu tốn $O(|V|)$ khủng khiếp khi từ điển lớn.

Giải pháp SGNS: Chuyển thành bài toán phân loại nhị phân giữa cặp thật (w_I, w_O) và K mẫu âm ngẫu nhiên:

$$\mathcal{L}_{\text{SGNS}} = \log \sigma(v_{w_O}^T v_{w_I}) + \sum_{k=1}^K \mathbb{E}_{w_{n_k}} \left[\log \sigma(-v_{w_{n_k}}^T v_{w_I}) \right]$$

- Độ phức tạp giảm từ $O(|V|) \rightarrow O(K)$ ($K \in [5, 20]$).
- Phân phối unigram mũ 3/4: $P_n(w) \propto f(w)^{3/4}$.

Học Biểu Diễn Văn Bản Bằng LSTM & Mạng BiLSTM

Cơ chế kiểm soát của LSTM (3 Cổng)

Khắc phục hiện tượng suy biến Gradient bằng **Ô nhớ dài hạn** c_t và 3 cổng logic:

- 1 **Cổng quên:** $f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$
- 2 **Cổng nạp:** $i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$
- 3 **Ứng viên nhớ:** $\tilde{c}_t = \tanh(W_c[h_{t-1}, x_t] + b_c)$
- 4 **Cập nhật ô nhớ:** $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$
- 5 **Cổng ra:** $o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$
- 6 **Trạng thái ẩn:** $h_t = o_t \odot \tanh(c_t)$

Mạng hồi quy hai chiều BiLSTM

Xử lý văn bản theo cả hai hướng đồng thời:

- Chiều xuôi: $\vec{h}_t = \text{LSTM}_{fwd}(x_t, \vec{h}_{t-1})$
- Chiều ngược: $\overleftarrow{h}_t = \text{LSTM}_{bwd}(x_t, \overleftarrow{h}_{t+1})$
- Kết hợp: $h_t = [\vec{h}_t; \overleftarrow{h}_t] \in \mathbb{R}^{2 \cdot d_{hidden}}$

Điểm nghẽn thông tin (Information Bottleneck)

BiLSTM thông thường lấy vector cuối: $v_D = [\vec{h}_T; \overleftarrow{h}_1]$.

→ Toàn bộ câu dài bị nén bắt buộc qua một vector duy nhất
⇒ suy giảm tín hiệu đầu câu!

Đề Xuất: Tích Hợp Additive Self-Attention & Khả Giải Thích XAI

Cơ chế Chú ý Tự thân (Additive Attention)

Tính **tổng có trọng số** của toàn bộ chuỗi trạng thái ẩn h_t , không bỏ rơi bất kỳ từ nào:

$$u_t = \tanh(W_a h_t + b_a)$$


$$\alpha_t = \frac{\exp(u_t^T u_w)}{\sum_{\tau=1}^T \exp(u_\tau^T u_w)}$$

$$v_D = \sum_{t=1}^T \alpha_t h_t$$

- u_w : Vector ngữ cảnh học được (*Context query*).
- $\alpha_t \in [0, 1]$ với $\sum_t \alpha_t = 1$: Trọng số đóng góp của từng token.

Giá trị Explainable AI (XAI) trực quan

Trọng số α_t biến mô hình từ "hộp đen" thành hệ thống trong suốt, có thể kiểm chứng:



→ Mô hình tập trung chính xác vào **tính từ phân cực cốt lõi**, loại bỏ hoàn toàn nhiễu từ hư từ.

Mô Hình Ngôn Ngữ SOTA Tiếng Việt: PhoBERT Base v2


Kiến trúc Transformer Tiền Huấn Luyện (VinAI Research)

- Dựa trên kiến trúc **RoBERTa-base**: 12 tầng Transformer Encoder, 12 attention heads, ẩn số $d_{model} = 768$, tổng **135 triệu tham số**.
- **Quy mô tiền huấn luyện**: 20GB văn bản tiếng Việt (3 tỷ token) thu thập từ Wikipedia và báo chí chính thống.
- **Cơ chế Tokenizer**: Tách từ âm tiết tiếng Việt kết hợp thuật toán Byte-Pair Encoding (**BPE**) với từ vựng 64,000 subwords → khắc phục triệt để lỗi OOV tuyệt đối.

Biểu diễn ngữ cảnh động (Contextualized Embeddings)

Khác với Word2Vec tĩnh, một từ trong PhoBERT sinh ra vector động tùy biến theo ngữ cảnh xung quanh → nắm bắt trọn vẹn phép đảo ngữ và hàm ý tinh tế.

Sơ đồ tinh chỉnh (Fine-tuning)



3. Thiết Kế Thử Nghiệm: 3 Miền Ngữ Liệu Thực Tế

Để kiểm chứng độ bền vững học thuật (**Generalization**), nhóm thử nghiệm song song trên 3 miền dữ liệu thực tế độc lập:

Đặc trưng	1. UIT-VSFC (Giáo dục)	2. E-Commerce (Thương mại)	3. Review-Phim (Điện ảnh IMDb)
Nguồn ngữ liệu	Ý kiến phản hồi SV ĐHQG TP.HCM	Đánh giá mua sắm sàn TMDT	Đánh giá phim điện ảnh IMDb
Quy mô mẫu	2,500 train / 600 test	2,500 train / 600 test	Tập kiểm thử chuẩn hóa
Phân bố nhãn	Cân bằng (300 Pos / 300 Neg)	Cân bằng (300 Pos / 300 Neg)	Cân bằng 2 lớp
Phong cách ngôn ngữ	Học thuật chuẩn mực, đúng chính tả	Ngôn ngữ MXH, tự do, cảm xúc	Nhận xét điện ảnh, phân tích kịch bản
Thách thức chính	Phủ định, góp ý lịch sự	Teencode (<i>sp, dc, ship, auth</i>), lỗi chính tả, mỉa mai	Cấu trúc tương phản dài (<i>khen diễn xuất nhưng chê kết phim</i>)

Ý nghĩa của thử nghiệm đa miền (Cross-Domain Evaluation)

Đánh giá độ nhạy cảm của các kiến trúc đối với hiện tượng dịch chuyển phân phối dữ liệu (**Distribution Shift**) và bùng nổ tỷ lệ từ ngoài từ điển (**OOV Explosion**).

Quy Trình Tiền Xử Lý 5 Bước & Cấu Hình Siêu Tham Số

Quy trình tiền xử lý 5 bước chuẩn hóa

- ➊ **Chuẩn hóa Unicode NFC:** Khắc phục hiện tượng 2 mã nhị phân cho cùng một ký tự tiếng Việt.
- ➋ **Lowercasing:** Đưa toàn bộ văn bản về dạng chữ thường.
- ➌ **Làm sạch ký tự thừa:** Loại URL, thẻ HTML, ký tự điều khiển rác, giữ dấu ngắt câu cơ bản.
- ➍ **Tách từ tiếng Việt (Pyvi):** Ghép từ phức bằng gạch dưới ("*nhiet tinh*" → "*nhiet_tinh*").
- ➎ **Vector hóa & Padding:** Đưa câu về độ dài chuẩn `max_len = 64`.

Cấu hình siêu tham số huấn luyện

- **Phần cứng:** Apple Silicon GPU (Metal - MPS), RAM 16GB.
- **Word2Vec (Gensim):** $d = 100$, `window = 5`, `min_count = 1`, `architecture = CBOW`, `epochs = 30`.
- **BiLSTM + Self-Attention:**
 - $d_{embed} = 100$, $d_{hidden} = 128$ ($2 \times 128 = 256$)
 - $d_{attn} = 64$, `Dropout = 0.3`, `Batch size = 32`
 - `Optimizer: Adam` ($\eta = 0.001$, `weight decay = 1e - 4`)
- **PhoBERT Base v2 (Transformers):**
 - `Batch size = 16`, `Epochs = 4`, `AdamW` ($\eta = 2e - 5$)
 - `Linear warmup & decay schedule`

4. Bảng Số Liệu Đối Chuẩn 6 Mô Hình Trên Cả 3 Miền Dữ Liệu

Số liệu đánh giá độc lập trên tập kiểm thử mỗi miền, khớp chính xác 100% với báo cáo chính thức:

STT	Kiến trúc Mô hình / Phương pháp	UIT-VSFC (Giáo dục)		E-Commerce (TMDT)		Review-Phim (IMDb)	
		Accuracy	F1-Score	Accuracy	F1-Score	Accuracy	F1-Score
1	TF-IDF + Logistic Regression (Baseline 1)	89.83%	89.80%	70.33%	69.65%	89.20%	89.54%
2	Average Word2Vec + LR (Baseline 2)	87.50%	87.49%	67.33%	66.80%	86.40%	86.82%
3	BiLSTM Scratch (Khởi tạo ngẫu nhiên)	89.17%	89.16%	69.17%	68.75%	88.10%	88.75%
4	BiLSTM Pretrained (Nạp sẵn Word2Vec)	91.00%	91.00%	67.17%	67.05%	90.80%	91.15%
5	BiLSTM + Self-Attention (Đề xuất XAI)	91.83%	91.83%	72.50%	72.40%	92.40%	92.80%
6	PhoBERT Base v2 (Transformer SOTA)	95.50%	95.50%	86.17%	86.16%	94.80%	95.10%

Đóng góp của Self-Attention


Tăng bất phá +5.33% trên E-Commerce (từ 67.17% lên 72.50%) nhờ khả năng lọc từ khóa mang cảm xúc trong câu nhiều.

Ưu thế vượt trội của PhoBERT

Đạt đỉnh 95.50% trên UIT-VSFC và duy trì độ chính xác cao 86.17% trên E-Commerce nhờ Tokenizer BPE và 12 tầng Attention.

Biểu Đồ So Sánh Hiệu Năng & Độ Bền Vững Đa Miền

Đối Chuẩn Hiệu Năng 6 Mô Hình trên 2 Bộ Dữ Liệu Thực Tế



Hình: Đối chuẩn Accuracy & F1 giữa 6 mô hình trên các tập dữ liệu.

Phân tích mức sụt giảm miền (ΔAcc)

Khi chuyển từ văn phong học thuật sang TMDT mạng xã hội, toàn bộ mô hình đều suy giảm do khác biệt phân phối:


- **TF-IDF:** Giảm 19.50% (89.83 $\rightarrow$ 70.33%)
- **Avg Word2Vec:** Giảm 20.17%
- **BiLSTM Scratch:** Giảm 20.00%
- **BiLSTM + Attention:** Giảm 19.33%
- **PhoBERT Base v2:** Chỉ giảm 9.33% (95.50 $\rightarrow$ 86.17%)

Kết luận kỹ thuật

PhoBERT bền vững nhất trước hiện tượng Domain Gap nhờ 20GB ngữ liệu tiền huấn luyện đa dạng.

Minh Chứng Trực Quan Hóa Trọng Số Chú Ý (Attention Heatmap)

Phân bố Attention (Tích cực) - UIT-VSFC



Hình: Trọng số Attention phân bố trên câu phản hồi sinh viên.


Bằng chứng thực nghiệm về tính khả giải thích

- **Hư từ & thực thể** (*thầy, cô, bài, sinh_viên*): Trọng số nền rất nhỏ ($\alpha_t \in [0.02, 0.06]$).
- **Tính từ phân cực quyết định** (*nhật_tình, xuất_sắc, dễ_hiểu, khó_chịu*): Nhận trọng số áp đảo ($\alpha_t \in [0.30, 0.48]$).

Giá trị ứng dụng thực tiễn


Giúp giảng viên và quản lý hệ thống ngay lập tức định vị được lý do vì sao một câu nhận xét bị đánh giá Tiêu cực hay Tích cực mà không cần đọc hết văn bản dài.

Tiến Hóa Không Gian Biểu Diễn Văn Bản Qua Chiều t-SNE




(a) Average Word2Vec

Ranh giới mờ nhạt, điểm Pos/Neg hòa lẫn ở vùng giữa.



(b) BiLSTM Representation

Phân tách rõ hai nhánh đối xứng nhờ học chuỗi thời gian.



(c) PhoBERT Contextual

Hai cụm cô đặc tuyệt đối, khoảng cách phân cách cực rộng.

Nhận xét từ t-SNE

Hình ảnh chiếu 2D minh chứng sắc nét lý do vì sao độ chính xác tăng dần từ 87.50% → 91.83% → 95.50%. Biểu diễn ngữ cảnh sâu của Transformer tạo ra siêu phẳng phân chia lớp tối ưu nhất.

Thảo Luận Học Thuật: Nghịch Lý Word2Vec & Giá Trị Transfer Learning

1. Vì sao Avg Word2Vec kém hơn cả TF-IDF?

Hiện tượng: Avg W2V đạt 87.50% trong khi TF-IDF đạt 89.83% trên UIT-VSFC.

- **Mất trật tự từ tính giao hoán:** Phép cộng vector $\frac{1}{|D|} \sum v_w$ biến "thầy dạy không khó hiểu" và "thầy dạy khó hiểu không" thành cùng 1 vector!
- **Nghịch lý triệt tiêu phủ định:** Từ "không" xuất hiện cạnh cả từ tốt và xấu $\rightarrow$ vector ở tâm. Phép trung bình xem phủ định như một sự **pha loãng** chứ không thể **đảo chiều** vector.
- **Ưu thế của TF-IDF:** Giữ nguyên từng từ độc lập, cho phép Logistic Regression gán trọng số âm lớn cho từ phủ định.

2. Giá trị Transfer Learning của Word2Vec

Hiện tượng: BiLSTM Pretrained tăng **+1.83%** so với BiLSTM Scratch (89.17% $\rightarrow$ 91.00%).

- **BiLSTM Scratch:** Tăng nhúng khởi tạo ngẫu nhiên; chỉ với 2,500 mẫu không đủ để học không gian hình học cho các từ hiếm.
- **BiLSTM Pretrained:** Được trang bị sẵn cấu trúc ngữ nghĩa từ kho ngữ liệu lớn. Mạng giải phóng tài nguyên để tập trung toàn lực vào **học lan truyền ngữ cảnh theo chuỗi thời gian**.
- Giúp mô hình hội tụ nhanh hơn gấp 2× và hạn chế hiện tượng overfitting.

Thảo Luận Học Thuật: Bứt Phá Của Attention & Thách Thức Domain Gap

3. Cơ chế nào giúp Attention bứt phá?

Tăng vượt bậc +5.33% trên E-Commerce (67.17% → 72.50%):

- **Xóa bỏ Information Bottleneck:** Không ép câu qua h_T mà tạo đường tắt trực tiếp từ mọi từ đến bộ phân loại ($v_D = \sum \alpha_t h_t$).
- **Soft Feature Selection:** Tự động hạ thấp trọng số hư từ và khuếch đại tính từ đối lập (rất quan trọng trong câu có cấu trúc tương phản: "Giao hàng nhanh nhưng đồ quá xấu").

4. Nguyên nhân sụt giảm khi sang E-Commerce?

Tất cả mô hình từ điển cố định đều sụt giảm 20% do:

- **Bùng nổ Out-of-Vocabulary (OOV):** Teencode (*sp, dc, ship, auth, fake*), viết tắt, sai chính tả tùy tiện.
- **Ngôn ngữ châm biếm / Sarcasm:** Dùng từ tích cực bề mặt để chê bai chất lượng.
- **PhoBERT bền bỉ nhất ($\Delta = 9.33\%$):** Nhờ cơ chế tách subwords BPE bẻ nhỏ từ lạ thành đơn vị con quen thuộc.

Phân Tích Lỗi Định Tính (Qualitative Error Analysis)

Nhóm tiến hành mổ xẻ các ca sai sót điển hình để xác định giới hạn kỹ thuật của các kiến trúc:

Trường hợp 1: Cấu trúc câu tương phản đảo hướng ngữ nghĩa

- **Câu kiểm thử:** "*Giao hàng hơi lâu nhưng chất lượng áo thì đỉnh chóp.*" → **Thực tế: TÍCH CỰC.**
- **BiLSTM dự đoán: Tiêu cực.**
- **Nguyên nhân:** Từ lỏng "*đỉnh chóp*" bị OOV; mạng đọc từ trái sang phải gặp "*hơi lâu*" gây lệch trạng thái ẩn ban đầu, chưa học được quy luật liên từ "*nhưng*" đảo hướng ngữ nghĩa.

Trường hợp 2: Ngôn ngữ mỉa mai / châm biếm (Sarcasm)

- **Câu kiểm thử:** "*Shop phục vụ quá nhiệt tình, nhấn tin 3 ngày mới thêm rep.*" → **Thực tế: TIÊU CỰC.**
- **Cả BiLSTM+Attention và PhoBERT đều dự đoán: Tích cực (Độ tin cậy > 90%).**
- **Nguyên nhân:** Thiếu tri thức đời thực (*World Knowledge*) rằng "*3 ngày*" là quá trễ. Cơ chế Attention bị đánh lừa bởi từ cực tính mạnh "*quá nhiệt tình*".

5. Hệ Thống Ứng Dụng Thời Gian Thực (Demo Application)


Kiến trúc Inference Engine đa nhiệm

Xây dựng hệ thống web demo hoàn chỉnh tích hợp:

- **3 Miền dữ liệu:** UIT-VSFC, E-Commerce, Review-Phim IMDb.
- **6 Kiến trúc mô hình:** Chạy song song và đo đặc độ trễ suy luận (*Latency*) thời gian thực.
- **Module XAI trực quan:** Sinh bản đồ nhiệt Attention Heatmap tương tác cho từng từ vựng.
- **Công nghệ:** Streamlit + PyTorch + Hugging Face Transformers + Pyvi.


Độ trễ suy luận thực tế (Latency)

TF-IDF / W2V: $\approx 5\text{ms}$ | BiLSTM: $\approx 15\text{ms}$ | PhoBERT: $\approx 65\text{ms}$.



Hình: Giao diện so sánh đồng thời 6 mô hình thời gian thực.

Trực Quan Hóa Giao Diện Suy Luận & Explainable AI



Hình: Bản đồ nhiệt Attention Heatmap trực quan hóa trên Web Demo.

Tính năng nổi bật của Web Demo

- **Phân tích từ khóa đóng góp:** Tự động bôi màu các từ có trọng số α_t cao theo dải màu trực quan.
- **Bộ mẫu câu thử nghiệm đa dạng:** Khen ngợi, phàn nàn, phủ định phức tạp, teencode mua sắm, review phim.
- **Chế độ so sánh đôi đầu:** Cho phép người dùng kiểm chứng ngay lập tức trường hợp mô hình nào thắng, mô hình nào thua.

Đường dẫn trải nghiệm

Khởi chạy tại máy qua script:
`cd Bai_tap_giua_ky && ./run_app.sh`

6. Kết Luận Nghiên Cứu

Thành quả nghiên cứu chính

- 1 **Làm chủ chuỗi công nghệ:** Từ Word2Vec tính đến mạng hồi quy hai chiều BiLSTM và Transformer SOTA PhoBERT.
- 2 **Chứng minh thành công cơ chế Self-Attention:** Vừa bứt phá độ chính xác (+5.33% trên E-Commerce), vừa giải quyết bài toán **hộp đen** bằng trọng số chú ý có thể giải thích được.
- 3 **Thực nghiệm đa miền chặt chẽ:** Chỉ ra sự sụt giảm hiệu năng do Domain Gap và minh chứng sự bền bỉ của Tokenizer BPE.
- 4 **Đóng gói sản phẩm hoàn chỉnh:** Hệ thống Web Demo trực quan, sẵn sàng triển khai và tái lập kết quả.

Hướng phát triển tiếp theo

- **Chuẩn hóa Teencode & Tiếng lóng:** Tích hợp module chuẩn hóa từ viết tắt tự động trước khi đưa vào mô hình tính.
- **Giải quyết bài toán Châm biếm (Sarcasm):** Bổ sung tri thức đồ thị (Knowledge Graph) hoặc áp dụng mô hình đa phương thức (Multimodal Sentiment Analysis).
- **Mô hình siêu nhẹ (Model Distillation):** Tinh gọn PhoBERT qua kỹ thuật chưng cất tri thức (DistilPhoBERT, TinyBERT) nhằm đạt độ trễ < 10ms trên thiết bị biên.



TRƯỜNG ĐẠI HỌC SƯ PHẠM TP. HỒ CHÍ MINH

KHOA CÔNG NGHỆ THÔNG TIN — LỚP CAO HỌC KHMT K36

CHÂN THÀNH CẢM ƠN THẦY VÀ CÁC BẠN ĐÃ LẮNG NGHE BÀI BÁO CÁO!

Giảng viên hướng dẫn: PGS.TS. LÊ ANH CƯỜNG

Nhóm 3: Trần Gia Huy • Đỗ Minh Khánh Ngân • Nguyễn Tấn Phát

HỎI & ĐÁP (Q&A)

Mã nguồn & Báo cáo: <https://github.com/trangiahuy8444/NLP>