



BÁO CÁO TIỂU LUẬN GIỮA KỲ — HỌC PHẦN XỬ LÝ NGÔN NGỮ TỰ NHIÊN

MÔ HÌNH WORD2VEC, WORD EMBEDDING VÀ HỌC BIỂU DIỄN VĂN BẢN BẰNG LSTM CHO BÀI TOÁN PHÂN LOẠI CẢM XÚC

Nghiên cứu lý thuyết, Hiện thực mô hình, Đối chuẩn Đa miền & Triển khai Ứng dụng XAI

Thông Tin Học Phần & Giảng Viên

Đơn vị: ĐH Sư phạm TP.HCM (HCMUE) — Khoa CNTT

Chuyên ngành: Cao học Khoa học Máy tính (K36)

Giảng viên hướng dẫn: **PGS.TS. LÊ ANH CƯỜNG**

Thời gian: Tháng 10/2026

Học Viên Thực Hiện (Nhóm 3)

1. **Trần Gia Huy** — MSHV: **KHMT836012**
2. **Đỗ Minh Khánh Ngân** — MSHV: **KHMT836019**
3. **Nguyễn Tấn Phát** — MSHV: **KHMT836026**

Hệ thống Web Demo: <http://localhost:8501>

❶ Đặt Vấn Đề & Mục Tiêu Nghiên Cứu

- Thách thức biểu diễn ngữ nghĩa tiếng Việt
- 7 đóng góp trọng tâm của nhóm học viên

❷ Cơ Sở Lý Thuyết & Kiến Trúc Mạng

- Không gian vector Word2Vec (CBOW vs Skip-Gram)
- Học chuỗi BiLSTM & Additive Attention
- Sơ đồ luồng dữ liệu kiến trúc đề xuất
- Vai trò đại diện toàn câu của token [CLS] (PhoBERT)

❸ Thiết Kế Thực Nghiệm & Đa Miền

- 3 miền ngữ liệu: UIT-VSFC, E-Commerce, Review-Phim
- Quy trình tiền xử lý 5 bước chuẩn hóa

❹ Kết Quả Đối Chuẩn & Đánh Giá

- Bảng đối chuẩn toàn diện: Accuracy, F1 & AUC-ROC
- Giải thích quyết định qua Attention Heatmap (XAI)
- Tiến hóa không gian biểu diễn văn bản qua t-SNE
- Thảo luận 4 luận điểm học thuật then chốt
- Phân tích lỗi định tính & Giải pháp kỹ thuật

❺ Sản Phẩm Ứng Dụng Thời Gian Thực

- Kiến trúc suy luận song song 6 mô hình
- Trải nghiệm Web Demo tương tác trực quan

❻ Kết Luận & Hướng Phát Triển

1. Đặt Vấn Đề: Thách Thức Biểu Diễn Ngữ Nghĩa Tiếng Việt



Thách thức cốt lõi của Biểu diễn từ

- Ánh xạ ngôn ngữ rời rạc sang vector dày đặc $\mathbb{R}^d$ bảo toàn **khoảng cách ngữ nghĩa**.
- **Đặc thù tiếng Việt**: Ngôn ngữ đơn lập, không biến hình, từ ghép, từ láy, đa nghĩa, đảo ngữ, cấu trúc phủ định và sắc thái châm biếm (*sarcasm*).
- **Giả thuyết phân bố (Firth, 1957)**: "*You shall know a word by the company it keeps*" — một từ được định nghĩa bởi các từ xuất hiện xung quanh nó.

Hạn chế của mô hình cổ điển (One-Hot, TF-IDF)

- **Bùng nổ số chiều**: Kích thước ma trận bằng $|V|$ ($10^4 - 10^5$), cực kỳ lãng phí bộ nhớ.
- **Tính trực giao tuyệt đối**: $e_i^T e_j = 0, \forall i \neq j$. Không đo được sự tương đồng giữa "*giảng viên*" và "*thầy cô*".
- **Mất trật tự từ (Bag-of-Words)**: Bỏ qua hoàn toàn cú pháp và phụ thuộc ngữ cảnh dài hạn.


1. Nghiên Cứu Lý Thuyết & Mô Hình Hóa

- **Làm chủ chuỗi biểu diễn:** Khảo sát hệ thống từ One-Hot, TF-IDF, Word2Vec (*CBOW*, *SGNS*) đến BiLSTM và PhoBERT SOTA.
- **Mô hình hóa chuỗi với BiLSTM:** Trích xuất vector biểu diễn câu v_D bất trợn ngữ cảnh xuôi - ngược.
- **Đề xuất Additive Self-Attention:** Giải quyết triệt để **nghẽn cổ chai thông tin** của LSTM, tăng độ chính xác và cung cấp khả năng giải thích quyết định (**XAI**).

2. Thực Nghiệm Đa Miền & Triển Khai Thực Tế

- **Đôi chuẩn đa miền (Cross-Domain):** Kiểm thử độc lập trên 3 miền: Giáo dục (**UIT-VSFC**), Thương mại (**E-Commerce**) và Điện ảnh (**IMDb**).
- **So sánh 6 mô hình song song:** Phân tích định lượng lẫn định tính nguyên nhân dịch chuyển phân phối dữ liệu (*Domain Gap*).
- **Trực quan hóa t-SNE & Heatmap:** Minh chứng quá trình tiến hóa hình học không gian vector.
- **Ứng dụng Web Demo tương tác:** Xây dựng giao diện suy luận thời gian thực hoàn chỉnh.

2. Tiến Trình Phát Triển Biểu Diễn Từ Trong NLP



Biểu Diễn Tĩnh (Static Embeddings)

- **Word2Vec, FastText, GloVe:** Mỗi từ vựng cố định một vector duy nhất trong không gian $\mathbb{R}^d$.
- **Hạn chế:** Từ đa nghĩa ("nước suối" vs "đất nước") dùng chung 1 vector; không xét ngữ cảnh cụ thể trong câu.

Biểu Diễn Động Theo Ngữ Cảnh (Contextual)

- **BiLSTM, Transformer, PhoBERT:** Vector của từ phụ thuộc hoàn toàn vào các từ đứng trước và sau nó.
- **Ưu thế vượt trội:** Giải quyết triệt để đa nghĩa, đảo ngữ, phụ thuộc xa (*Long-range dependencies*).

CBOW vs Skip-Gram (Mục Tiêu Tối Ưu)

CBOW: Dự đoán từ tâm w_t từ ngữ cảnh $w_{t \pm c}$:

$$\mathcal{L}_{\text{CBOW}} = \sum_{t=1}^T \log P(w_t \mid w_{t-c}, \dots, w_{t+c})$$

Skip-Gram: Từ từ tâm w_t , dự đoán ngữ cảnh:

$$\mathcal{L}_{\text{SG}} = \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log P(w_{t+j} \mid w_t)$$

Skip-Gram học từ hiếm và ngữ nghĩa đa dạng rất tốt.

Negative Sampling (SGNS) Tối Ưu Tốc Độ

Vấn đề Softmax: Mẫu số $\sum_{w' \in V} \exp(v_{w'}^T v_{w_i})$ tốn $O(|V|)$.

Giải pháp SGNS: Phân loại nhị phân giữa cặp thật (w_i, w_o) và K mẫu âm ($K \in [5, 20]$):

$$\mathcal{L}_{\text{SGNS}} = \log \sigma(v_{w_o}^T v_{w_i}) + \sum_{k=1}^K \mathbb{E}_{w_{n_k}} \left[\log \sigma(-v_{w_{n_k}}^T v_{w_i}) \right]$$

- Giảm độ phức tạp từ $O(|V|) \rightarrow O(K)$.
- Phân phối unigram mũ 3/4: $P_n(w) \propto f(w)^{3/4}$.

So Sánh Đối Đầu Kỹ Thuật: CBOW vs Skip-Gram



Bảng tổng hợp đối chiếu trực tiếp các tiêu chí cốt lõi giữa hai kiến trúc Word2Vec kinh điển:

Tiêu chí so sánh	CBOW (Continuous Bag-of-Words)	Skip-Gram (với Negative Sampling)
Cơ chế dự đoán	Dự đoán từ trung tâm w_t dựa vào ngữ cảnh	Dự đoán các từ ngữ cảnh w_{t+j} từ từ tâm w_t
Tốc độ huấn luyện	Rất nhanh (gấp nhiều lần Skip-Gram)	Chậm hơn do xét từng cặp từ trong cửa sổ
Khả năng học từ hiếm	Trung bình (bị lấn át bởi các từ phổ biến)	Xuất sắc (học hình học vector rất kỹ cho từ hiếm)
Độ phức tạp tính toán	$O(C \times d + d \times \log V)$	$O(C \times (d + d \times K))$ với SGNS (K mẫu âm)
Ngữ liệu phù hợp	Kho văn bản lớn, ưu tiên tốc độ hội tụ	Dữ liệu vừa/nhỏ, yêu cầu ngữ nghĩa từ hiếm sâu

Lựa chọn thực nghiệm trong đề tài

Đề tài sử dụng **Word2Vec CBOW** ($d = 100$, $window=5$, $min_count=1$, 30 epochs) để tạo pretrained embedding, đồng thời đối chuẩn độc lập với Skip-Gram để kiểm chứng tính bền vững của không gian vector ngữ nghĩa.

Cơ chế kiểm soát của LSTM (3 Cổng)

Khắc phục suy biến Gradient bằng **Ô nhớ** c_t và 3 cổng:

- 1 **Cổng quên**: $f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$
- 2 **Cổng nạp**: $i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$
- 3 **Ứng viên nhớ**: $\tilde{c}_t = \tanh(W_c[h_{t-1}, x_t] + b_c)$
- 4 **Cập nhật ô nhớ**: $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$
- 5 **Cổng ra**: $o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$
- 6 **Trạng thái ẩn**: $h_t = o_t \odot \tanh(c_t)$

Mạng hồi quy hai chiều BiLSTM

Xử lý văn bản theo cả hai hướng đồng thời:

- Chiều xuôi: $\vec{h}_t = \text{LSTM}_{fwd}(x_t, \vec{h}_{t-1})$
- Chiều ngược: $\overleftarrow{h}_t = \text{LSTM}_{bwd}(x_t, \overleftarrow{h}_{t+1})$
- Kết hợp: $h_t = [\vec{h}_t; \overleftarrow{h}_t] \in \mathbb{R}^{2 \cdot d_{\text{hidden}}}$

Điểm nghẽn thông tin (Bottleneck)

BiLSTM thông thường lấy vector cuối: $v_D = [\vec{h}_T; \overleftarrow{h}_1]$.
→ Câu dài bị nén qua một vector duy nhất $\Rightarrow$ suy giảm tín hiệu đầu câu!

Cơ chế Chú ý Tự thân (Additive Attention)

Tính **tổng có trọng số** của toàn bộ chuỗi trạng thái ẩn h_t , không bỏ rơi bất kỳ từ nào:

$$u_t = \tanh(W_a h_t + b_a)$$

$$\alpha_t = \frac{\exp(u_t^T u_w)}{\sum_{\tau=1}^T \exp(u_\tau^T u_w)}, \quad v_D = \sum_{t=1}^T \alpha_t h_t$$

- u_w : Vector ngữ cảnh học được (*Context query*).
- $\alpha_t \in [0, 1]$ với $\sum_t \alpha_t = 1$: Trọng số đóng góp token.

Giá trị Explainable AI (XAI) trực quan


Trọng số α_t biến mô hình thành trong suốt, kiểm chứng được:

thầy (0.04) dạy (0.05) rất (0.12) **nhật_tình (0.42)** **dễ_hiểu (0.34)**

Dự đoán: TÍCH CỰC (Độ tin cậy 98.6%)

→ Mô hình dồn trọng số vào **tính từ phân cực cốt lõi**, loại bỏ hoàn toàn nhiễu từ hư từ.

Sơ Đồ Luồng Kiến Trúc: BiLSTM + Additive Attention



Biến Đổi Không Gian Tensor Qua Các Tầng

- $X \in \mathbb{R}^{B \times T \times 100}$: Ma trận nhúng từ dày đặc nạp sẵn.
- $H \in \mathbb{R}^{B \times T \times 256}$: Trạng thái ẩn bất trọn 2 chiều ngữ cảnh.
- $\alpha \in \mathbb{R}^{B \times T}$: Trọng số chú ý chuẩn hóa ($\sum \alpha_t = 1$).
- $v_D \in \mathbb{R}^{B \times 256}$: Vector câu duy nhất đưa vào bộ phân loại.

3 Đột Phá So Với BiLSTM Truyền Thống

- **Xóa nghẽn cổ chai**: Không ép câu dài qua h_T , tạo kết nối trực tiếp từ mọi từ đến đầu ra.
- **Khử nhiễu tự thích nghi**: Hư từ tự động nhận $\alpha_t \rightarrow 0$, tính từ phân cực nhận $\alpha_t \rightarrow 0.45$.
- **Minh bạch hóa (XAI)**: Trích xuất trực tiếp α_t thành heatmap kiểm chứng tính hợp lý của quyết định.


Kiến trúc Transformer Tiền Huấn Luyện

- **Cấu trúc RoBERTa-base:** 12 tầng Encoder, 12 heads, $d_{model} = 768$, tổng **135 triệu tham số**.
- **Dữ liệu tiền huấn luyện:** 20GB văn bản tiếng Việt (3 tỷ token) từ Wikipedia và báo chí chính thống.
- **Tokenizer BPE:** 64,000 subwords $\rightarrow$ loại bỏ triệt để hiện tượng Out-of-Vocabulary (OOV).

Tại sao lấy vector [CLS] thay vì trung bình?

- Token đặc biệt $\langle s \rangle$ ([CLS]) không đại diện cho từ cụ thể nào.
- Nhờ **Multi-Head Attention 12 tầng**, [CLS] trực tiếp kết nối và tổng hợp ngữ nghĩa toàn câu $\Rightarrow$ là vector nền $\mathbb{R}^{768}$ tối ưu nhất cho bài toán phân loại.

Sơ đồ tinh chỉnh (Fine-tuning)



3. Thiết Kế Thử Nghiệm: 3 Miền Ngữ Liệu Thực Tế



Để kiểm chứng độ bền vững học thuật (**Generalization**), nhóm thử nghiệm song song trên 3 miền dữ liệu thực tế:

Đặc trưng	1. UIT-VSFC (Giáo dục)	2. E-Commerce (Thương mại)	3. Review-Phim (Điện ảnh IMDb)
Nguồn ngữ liệu	Ý kiến phản hồi SV ĐHQG TP.HCM	Đánh giá mua sắm sàn TMDT	Đánh giá phim điện ảnh IMDb
Quy mô mẫu	2,500 train / 600 test	2,500 train / 600 test	Tập kiểm thử chuẩn hóa
Phân bố nhãn	Cân bằng (300 Pos / 300 Neg)	Cân bằng (300 Pos / 300 Neg)	Cân bằng 2 lớp
Phong cách ngôn ngữ	Học thuật chuẩn mực, đúng chính tả	Ngôn ngữ MXH, tự do, cảm xúc	Nhận xét điện ảnh, phân tích kịch bản
Thách thức chính	Phủ định, góp ý lịch sự	Teencode (<i>sp, dc, ship, auth</i>), lỗi chính tả, mĩa mai	Cấu trúc tương phản dài (<i>khen diễn xuất nhưng chê kết phim</i>)

Ý nghĩa của thử nghiệm đa miền (Cross-Domain Evaluation)

Đánh giá độ nhạy cảm của các kiến trúc đối với hiện tượng dịch chuyển phân phối dữ liệu (**Distribution Shift**) và bùng nổ tỷ lệ từ ngoài từ điển (**OOV Explosion**).

Quy trình tiền xử lý 5 bước chuẩn hóa

- 1 **Chuẩn hóa Unicode NFC:** Khắc phục hiện tượng 2 mã nhị phân cho cùng một ký tự tiếng Việt.
- 2 **Lowercasing:** Đưa toàn bộ văn bản về dạng chữ thường.
- 3 **Làm sạch ký tự thừa:** Loại URL, thẻ HTML, ký tự điều khiển rác, giữ dấu ngắt câu cơ bản.
- 4 **Tách từ tiếng Việt (Pyvi):** Ghép từ phức bằng gạch dưới ("*nhiet tinh*" → "*nhiet_tinh*").
- 5 **Vector hóa & Padding:** Đưa câu về độ dài chuẩn `max_len = 64`.

Cấu hình siêu tham số huấn luyện

- **Phần cứng:** Apple Silicon GPU (Metal - MPS), RAM 16GB.
- **Word2Vec (Gensim):** $d = 100$, $\text{window} = 5$, $\text{min_count} = 1$, $\text{architecture} = \text{CBOW}$, $\text{epochs} = 30$.
- **BiLSTM + Self-Attention:**
 - $d_{\text{embed}} = 100$, $d_{\text{hidden}} = 128$ ($2 \times 128 = 256$)
 - $d_{\text{attn}} = 64$, Dropout = 0.3, Batch size = 32
 - Optimizer: Adam ($\eta = 0.001$, weight decay = $1e - 4$)
- **PhoBERT Base v2 (Transformers):**
 - Batch size = 16, Epochs = 4, AdamW ($\eta = 2e - 5$)
 - Linear warmup & decay schedule

4. Đối Chuẩn Toàn Diện: Accuracy, F1-Score & AUC-ROC



Đánh giá đa chiều trên cả 3 miền dữ liệu kiểm thử, bổ sung chỉ số **AUC-ROC** phản ánh năng lực phân tách phân phối:


STT	Kiến trúc Mô hình / Phương pháp	UIT-VSFC (Giáo dục)			E-Commerce (TMDT)			Review-Phim (IMDb)		
		Acc	F1	AUC	Acc	F1	AUC	Acc	F1	AUC
1	TF-IDF + Logistic Regression (Baseline 1)	89.83%	89.80%	0.952	70.33%	69.65%	0.765	89.20%	89.54%	0.948
2	Average Word2Vec + LR (Baseline 2)	87.50%	87.49%	0.938	67.33%	66.80%	0.732	86.40%	86.82%	0.925
3	BiLSTM Scratch (Khởi tạo ngẫu nhiên)	89.17%	89.16%	0.949	69.17%	68.75%	0.751	88.10%	88.75%	0.941
4	BiLSTM Pretrained (Nạp sẵn Word2Vec)	91.00%	91.00%	0.963	67.17%	67.05%	0.738	90.80%	91.15%	0.961
5	BiLSTM + Self-Attention (Đề xuất XAI)	91.83%	91.83%	0.971	72.50%	72.40%	0.798	92.40%	92.80%	0.974
6	PhoBERT Base v2 (Transformer SOTA)	95.50%	95.50%	0.989	86.17%	86.16%	0.924	94.80%	95.10%	0.988

Ý nghĩa chỉ số AUC-ROC

AUC tiệm cận 1.0 khẳng định ngưỡng phân cách tối ưu giữa 2 lớp cảm xúc. BiLSTM+Attention đạt **AUC 0.971**, vượt trội mô hình nhúng tĩnh.

Ưu thế của PhoBERT SOTA

Đạt **AUC 0.989** trên giáo dục và duy trì **AUC 0.924** trên TMDT, chứng minh năng lực phân loại vượt trội trước nhiễu ngôn ngữ.



Hình: Đôi chuẩn Accuracy & F1 giữa 6 mô hình trên các tập dữ liệu.


Phân tích mức sụt giảm miền (ΔAcc)

Khi chuyển sang TMDT MXH, các mô hình đều giảm do khác biệt phân phối:

- **TF-IDF**: Giảm 19.50% (89.83 $\rightarrow$ 70.33%)
- **Avg Word2Vec**: Giảm 20.17%
- **BiLSTM Scratch**: Giảm 20.00%
- **BiLSTM + Attention**: Giảm 19.33%
- **PhoBERT Base v2**: **Chỉ giảm 9.33%** (95.50 $\rightarrow$ 86.17%)

Kết luận kỹ thuật

PhoBERT bền vững nhất trước Domain Gap nhờ 20GB ngữ liệu tiền huấn luyện đa dạng.



Hình: Trọng số Attention phân bố trên câu phản hồi sinh viên.

Bảng chứng thực nghiệm về tính khả giải thích

- **Hư từ & thực thể** (*thầy, cô, bài, sinh_viên*): Trọng số nền rất nhỏ ($\alpha_t \in [0.02, 0.06]$).
- **Tính từ phân cực quyết định** (*nhật_tình, xuất_sắc, dễ_hiếu*): Nhận trọng số áp đảo ($\alpha_t \in [0.30, 0.48]$).


Giá trị ứng dụng thực tiễn

Giúp định vị ngay lập tức lý do một nhận xét bị đánh giá Tiêu cực hay Tích cực mà không cần đọc hết văn bản dài.

Tiến Hóa Không Gian Biểu Diễn Văn Bản Qua Chiều t-SNE




TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH
Ho Chi Minh City University of Education




(a) Average Word2Vec

Ranh giới mờ nhạt, điểm Pos/Neg hòa lẫn ở vùng giữa.



(b) BiLSTM Representation

Phân tách rõ hai nhánh đối xứng nhờ học chuỗi thời gian.



(c) PhoBERT Contextual

Hai cụm cô đặc tuyệt đối, khoảng cách phân cách cực rộng.

Nhận xét từ t-SNE

Hình ảnh chiếu 2D minh chứng sắc nét lý do vì sao độ chính xác tăng dần từ 87.50% → 91.83% → 95.50%. Biểu diễn ngữ cảnh sâu của Transformer tạo ra siêu phẳng phân chia lớp tối ưu nhất.

1. Vì sao Avg Word2Vec kém hơn TF-IDF?

- **Mất trật tự từ tính giao hoán:** Phép cộng $\frac{1}{|D|} \sum v_w$ biến "*không khó hiểu*" và "*khó hiểu không*" thành cùng vector!
- **Nghịch lý triệt tiêu phủ định:** Từ "*không*" ở tâm không gian; phép cộng chỉ **pha loãng** chứ không thể **đảo chiều** cực tính vector.
- **TF-IDF giữ độc lập:** Logistic Regression gán trọng số âm lớn cho từ phủ định rất hiệu quả.

2. Giá trị Transfer Learning Pretrained W2V

- **Bứt phá độ chính xác:** BiLSTM Pretrained tăng **+1.83%** so với khởi tạo ngẫu nhiên Scratch.
- **Giải phóng năng lực học:** Mạng không phải học hình học từ đầu; toàn lực tập trung vào **học lan truyền ngữ cảnh theo thời gian**.
- **Hội tụ nhanh 2x:** Hạn chế tối đa hiện tượng quá khớp (overfitting) trên tập dữ liệu nhỏ.

3. Cơ chế giúp Attention bứt phá?

- **Bứt phá +5.33% trên E-Commerce:** Tăng từ 67.17% lên **72.50%**.
- **Xóa bỏ Information Bottleneck:** Không ép câu qua h_T ; tạo đường tắt kết nối trực tiếp mọi token tới bộ phân loại.
- **Soft Feature Selection:** Tự động hạ thấp trọng số hư từ, khuếch đại tính từ đối lập trong câu phức.

4. Nguyên nhân sụt giảm khi sang TMDT?

- **Bùng nổ Out-of-Vocabulary (OOV):** Teencode (*sp, auth, ship*), viết tắt tùy tiện khiến mô hình tĩnh tê liệt.
- **Châm biếm / Sarcasm:** Dùng từ tích cực bề mặt để chê bai chất lượng sản phẩm.
- **PhoBERT bền bỉ nhất ($\Delta = 9.33\%$):** Nhờ cơ chế tách subwords BPE nhỏ từ lạ thành đơn vị con.

Ca 1: Cấu trúc câu tương phản đảo hướng

- **Thực tế:** "Giao hàng hơi lâu nhưng chất lượng áo thì đỉnh chóp." → **TÍCH CỰC**.
- **BiLSTM dự đoán:** Tiêu cực (Lỗi OOV từ lóng và trượt theo về "hơi lâu").

⇒ **Giải pháp kỹ thuật khắc phục:**

- ① **Phân rã liên từ nghịch tiếp:** Tách về sau "nhưng" và tăng trọng số phạt (Contrastive Loss Weighting).
- ② **Bổ sung từ điển Teencode:** Chuẩn hóa tự động "đỉnh chóp" → "rất tốt".

Ca 2: Ngôn ngữ mỉa mai / châm biếm (Sarcasm)

- **Thực tế:** "Shop phục vụ quá nhiệt tình, nhấn tin 3 ngày mới thêm rep." → **TIÊU CỰC**.
- **Cả BiLSTM và PhoBERT:** Đoán Tích cực (Bị đánh lừa bởi cụm "quá nhiệt tình").

⇒ **Giải pháp kỹ thuật khắc phục:**

- ① **Tích hợp Đồ thị Tri thức (Knowledge Graph):** Bổ sung tri thức đời thực: "chờ 3 ngày" là sự cố trễ hạn.
- ② **Suy luận Chuỗi tư duy (Chain-of-Thought):** Fine-tune với reasoning steps kiểm tra tính tương phản hành vi.

5. Hệ Thống Ứng Dụng Thời Gian Thực (Demo Application)


Kiến trúc Inference Engine đa nhiệm

Xây dựng hệ thống web demo hoàn chỉnh tích hợp:


- **3 Miền dữ liệu:** UIT-VSFC, E-Commerce, Review-Phim IMDb.
- **6 Kiến trúc mô hình:** Chạy song song và đo đặc độ trễ suy luận (*Latency*) thời gian thực.
- **Module XAI trực quan:** Sinh bản đồ nhiệt Attention Heatmap tương tác cho từng từ vựng.
- **Công nghệ:** Streamlit + PyTorch + Transformers + Pyvi.

Độ trễ suy luận thực tế (Latency)

TF-IDF / W2V: $\approx 5\text{ms}$ | BiLSTM: $\approx 15\text{ms}$ | PhoBERT: $\approx 65\text{ms}$.



Hình: Giao diện so sánh đồng thời 6 mô hình thời gian thực.



Hình: Bản đồ nhiệt Attention Heatmap trực quan hóa trên Web Demo.

Tính năng nổi bật của Web Demo

- **Phân tích từ khóa đóng góp:** Tự động tô màu các từ có trọng số α_t cao theo dải màu trực quan.
- **Bộ mẫu câu phong phú:** Khen ngợi, phàn nàn, phủ định phức tạp, teencode mua sắm, review phim.
- **So sánh đối đầu:** Kiểm chứng tức thì trường hợp mô hình nào thắng, mô hình nào thua.

Đường dẫn trải nghiệm

Khởi chạy tại máy qua script:
`cd Bai_tap_giua_ky && ./run_app.sh`

6. Kết Luận Nghiên Cứu



Thành quả nghiên cứu chính

- ❶ **Làm chủ chuỗi công nghệ:** Từ Word2Vec tĩnh đến BiLSTM và Transformer SOTA PhoBERT.
- ❷ **Chứng minh thành công Self-Attention:** Bứt phá độ chính xác (+5.33% trên E-Commerce), mở toang hộp đen với trọng số chú ý giải thích được.
- ❸ **Thực nghiệm đa miền chặt chẽ:** Chỉ ra Domain Gap và chứng minh sự bền bỉ của Tokenizer BPE.
- ❹ **Đóng gói sản phẩm hoàn chỉnh:** Web Demo trực quan, sẵn sàng kiểm chứng thực tế.

Hướng phát triển tiếp theo

- **Chuẩn hóa Teencode & Tiếng lóng:** Tích hợp module chuẩn hóa từ viết tắt tự động.
- **Xử lý Châm biếm (Sarcasm):** Bổ sung tri thức đồ thị (Knowledge Graph) hoặc đa phương thức.
- **Mô hình siêu nhẹ (Distillation):** Tinh gọn PhoBERT (DistilPhoBERT, TinyBERT) để đạt độ trễ < 10ms trên thiết bị biên.



TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH
Ho Chi Minh City University of Education

KHOA CÔNG NGHỆ THÔNG TIN — LỚP CAO HỌC KHMT K36

CHÂN THÀNH CẢM ƠN THẦY VÀ CÁC BẠN ĐÃ LẮNG NGHE BÀI BÁO CÁO!

Giảng viên hướng dẫn: PGS.TS. LÊ ANH CƯỜNG

Nhóm 3: Trần Gia Huy • Đỗ Minh Khánh Ngân • Nguyễn Tấn Phát

HỎI & ĐÁP (Q&A)

Mã nguồn & Báo cáo: <https://github.com/trangiahuy8444/NLP>