



BÁO CÁO TIỂU LUẬN GIỮA KỲ — HỌC PHẦN XỬ LÝ NGÔN NGỮ TỰ NHIÊN

MÔ HÌNH WORD2VEC, WORD EMBEDDING VÀ HỌC BIỂU DIỄN VĂN BẢN BẰNG LSTM CHO BÀI TOÁN PHÂN LOẠI CẢM XÚC

Nghiên cứu lý thuyết, Hiện thực mô hình, Đối chuẩn Đa miền & Triển khai Ứng dụng XAI

Thông Tin Học Phần & Giảng Viên

Đơn vị: ĐH Sư phạm TP.HCM (HCMUE) — Khoa CNTT

Chuyên ngành: Cao học Khoa học Máy tính (K36)

Giảng viên hướng dẫn: **PGS.TS. LÊ ANH CƯỜNG**

Thời gian: Tháng 10/2026

Học Viên Thực Hiện (Nhóm 3)

1. **Trần Gia Huy** — MSHV: **KHMT836012**
2. **Đỗ Minh Khánh Ngân** — MSHV: **KHMT836019**
3. **Nguyễn Tấn Phát** — MSHV: **KHMT836026**

Hệ thống Web Demo: <http://localhost:8501>

❶ Đặt Vấn Đề & Mục Tiêu Nghiên Cứu

- Thách thức biểu diễn ngữ nghĩa tiếng Việt
- 7 đóng góp trọng tâm của nhóm học viên

❷ Cơ Sở Lý Thuyết & Kiến Trúc

- Không gian vector Word2Vec (CBOW, Skip-Gram, SGNS)
- Học biểu diễn chuỗi bằng BiLSTM
- Cơ chế Chú ý Additive Self-Attention & XAI
- Mô hình ngôn ngữ ngữ cảnh SOTA: PhoBERT

❸ Thiết Kế Thực Nghiệm & Đa Miền

- 3 miền ngữ liệu: UIT-VSFC, E-Commerce, Review-Phim
- Quy trình tiền xử lý 5 bước chuẩn hóa

❹ Kết Quả Đối Chuẩn & Đánh Giá

- Bảng đối chuẩn toàn diện 6 mô hình trên 3 miền
- Giải thích quyết định qua Attention Heatmap (XAI)
- Tiến hóa không gian biểu diễn văn bản qua t-SNE
- Thảo luận 4 luận điểm học thuật then chốt
- Phân tích lỗi định tính (Qualitative Error Analysis)

❺ Sản Phẩm Ứng Dụng Thời Gian Thực

- Kiến trúc suy luận song song 6 mô hình
- Trải nghiệm Web Demo tương tác trực quan

❻ Kết Luận & Hướng Phát Triển

1. Đặt Vấn Đề: Thách Thức Biểu Diễn Ngữ Nghĩa Tiếng Việt



Thách thức cốt lõi của Biểu diễn từ

- Ánh xạ ngôn ngữ rời rạc sang vector dày đặc $\mathbb{R}^d$ bảo toàn **khoảng cách ngữ nghĩa**.
- **Đặc thù tiếng Việt**: Ngôn ngữ đơn lập, không biến hình, từ ghép, từ láy, đa nghĩa, đảo ngữ, cấu trúc phủ định và sắc thái châm biếm (*sarcasm*).
- **Giả thuyết phân bố (Firth, 1957)**: "*You shall know a word by the company it keeps*" — một từ được định nghĩa bởi các từ xuất hiện xung quanh nó.

Hạn chế của mô hình cổ điển (One-Hot, TF-IDF)

- **Bùng nổ số chiều**: Kích thước ma trận bằng $|V|$ ($10^4 - 10^5$), cực kỳ lãng phí bộ nhớ.
- **Tính trực giao tuyệt đối**: $e_i^T e_j = 0, \forall i \neq j$. Không đo được sự tương đồng giữa "*giảng viên*" và "*thầy cô*".
- **Mất trật tự từ (Bag-of-Words)**: Bỏ qua hoàn toàn cú pháp và phụ thuộc ngữ cảnh dài hạn.


1. Nghiên Cứu Lý Thuyết & Mô Hình Hóa

- **Làm chủ chuỗi biểu diễn:** Khảo sát hệ thống từ One-Hot, TF-IDF, Word2Vec (*CBOW*, *SGNS*) đến BiLSTM và PhoBERT SOTA.
- **Mô hình hóa chuỗi với BiLSTM:** Trích xuất vector biểu diễn câu v_D bất trộn ngữ cảnh xuôi - ngược.
- **Đề xuất Additive Self-Attention:** Giải quyết triệt để **nghẽn cổ chai thông tin** của LSTM, tăng độ chính xác và cung cấp khả năng giải thích quyết định (**XAI**).

2. Thực Nghiệm Đa Miền & Triển Khai Thực Tế

- **Đôi chuẩn đa miền (Cross-Domain):** Kiểm thử độc lập trên 3 miền: Giáo dục (**UIT-VSFC**), Thương mại (**E-Commerce**) và Điện ảnh (**IMDb**).
- **So sánh 6 mô hình song song:** Phân tích định lượng lẫn định tính nguyên nhân dịch chuyển phân phối dữ liệu (*Domain Gap*).
- **Trực quan hóa t-SNE & Heatmap:** Minh chứng quá trình tiến hóa hình học không gian vector.
- **Ứng dụng Web Demo tương tác:** Xây dựng giao diện suy luận thời gian thực hoàn chỉnh.

2. Tiến Trình Phát Triển Biểu Diễn Từ Trong NLP



Biểu Diễn Tĩnh (Static Embeddings)

- **Word2Vec, FastText, GloVe:** Mỗi từ vựng cố định một vector duy nhất trong không gian $\mathbb{R}^d$.
- **Hạn chế:** Từ đa nghĩa ("*nước suối*" vs "*đất nước*") dùng chung 1 vector; không xét ngữ cảnh cụ thể trong câu.

Biểu Diễn Động Theo Ngữ Cảnh (Contextual)

- **BiLSTM, Transformer, PhoBERT:** Vector của từ phụ thuộc hoàn toàn vào các từ đứng trước và sau nó.
- **Ưu thế vượt trội:** Giải quyết triệt để đa nghĩa, đảo ngữ, phụ thuộc xa (*Long-range dependencies*).

CBOW vs Skip-Gram

CBOW: Dự đoán từ trung tâm w_t từ ngữ cảnh xung quanh:

$$\mathcal{L}_{\text{CBOW}} = \sum_{t=1}^T \log P(w_t \mid w_{t-c}, \dots, w_{t+c})$$

Skip-Gram: Từ từ trung tâm, dự đoán ngữ cảnh:

$$\mathcal{L}_{\text{SG}} = \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log P(w_{t+j} \mid w_t)$$

Skip-Gram học từ hiếm và ngữ nghĩa đa dạng rất tốt.

Tối ưu hóa: Negative Sampling (SGNS)

Vấn đề Softmax: Mẫu số $\sum_{w' \in V} \exp(v_{w'}^T v_w)$ tiêu tốn $O(|V|)$ khi từ điển lớn.

Giải pháp SGNS: Phân loại nhị phân giữa cặp thật (w_I, w_O) và K mẫu âm:

$$\mathcal{L}_{\text{SGNS}} = \log \sigma(v_{w_O}^T v_{w_I}) + \sum_{k=1}^K \mathbb{E}_{w_{n_k}} \left[\log \sigma(-v_{w_{n_k}}^T v_{w_I}) \right]$$

- Giảm độ phức tạp từ $O(|V|) \rightarrow O(K)$ ($K \in [5, 20]$).
- Phân phối unigram mũ 3/4: $P_n(w) \propto f(w)^{3/4}$.

Cơ chế kiểm soát của LSTM (3 Cổng)

Khắc phục suy biến Gradient bằng **Ô nhớ** c_t và 3 cổng:

- 1 **Cổng quên**: $f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$
- 2 **Cổng nạp**: $i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$
- 3 **Ứng viên nhớ**: $\tilde{c}_t = \tanh(W_c[h_{t-1}, x_t] + b_c)$
- 4 **Cập nhật ô nhớ**: $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$
- 5 **Cổng ra**: $o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$
- 6 **Trạng thái ẩn**: $h_t = o_t \odot \tanh(c_t)$

Mạng hồi quy hai chiều BiLSTM

Xử lý văn bản theo cả hai hướng đồng thời:

- Chiều xuôi: $\vec{h}_t = \text{LSTM}_{fwd}(x_t, \vec{h}_{t-1})$
- Chiều ngược: $\overleftarrow{h}_t = \text{LSTM}_{bwd}(x_t, \overleftarrow{h}_{t+1})$
- Kết hợp: $h_t = [\vec{h}_t; \overleftarrow{h}_t] \in \mathbb{R}^{2 \cdot d_{\text{hidden}}}$

Điểm nghẽn thông tin (Bottleneck)

BiLSTM thông thường lấy vector cuối: $v_D = [\vec{h}_T; \overleftarrow{h}_1]$.
→ Câu dài bị nén qua một vector duy nhất $\Rightarrow$ suy giảm tín hiệu đầu câu!

Cơ chế Chú ý Tự thân (Additive Attention)

Tính **tổng có trọng số** của toàn bộ chuỗi trạng thái ẩn h_t , không bỏ rơi bất kỳ từ nào:

$$u_t = \tanh(W_a h_t + b_a)$$

$$\alpha_t = \frac{\exp(u_t^T u_w)}{\sum_{\tau=1}^T \exp(u_\tau^T u_w)}$$

$$v_D = \sum_{t=1}^T \alpha_t h_t$$

- u_w : Vector ngữ cảnh học được (*Context query*).
- $\alpha_t \in [0, 1]$ với $\sum_t \alpha_t = 1$: Trọng số đóng góp token.

Giá trị Explainable AI (XAI) trực quan

Trọng số α_t biến mô hình thành trong suốt, kiểm chứng được:

thầy (0.04) dạy (0.05) rất (0.12) **nhật_tình (0.42)** **dễ_hiếu (0.34)**


Dự đoán: **TÍCH CỰC** (Độ tin cậy 98.6%)

→ Mô hình dồn trọng số vào **tính từ phân cực cốt lõi**, loại bỏ hoàn toàn nhiễu từ hư từ.

Kiến trúc Transformer Tiền Huấn Luyện

- **Cấu trúc RoBERTa-base:** 12 tầng Transformer Encoder, 12 attention heads, ẩn số $d_{model} = 768$, tổng **135 triệu tham số**.
- **Dữ liệu tiền huấn luyện:** 20GB văn bản tiếng Việt (3 tỷ token) từ Wikipedia và báo chí chính thống.
- **Tokenizer BPE:** Tách từ âm tiết kết hợp Byte-Pair Encoding với 64,000 subwords $\rightarrow$ loại bỏ triệt để OOV.
- **Biểu diễn động:** Vector thay đổi linh hoạt theo từng ngữ cảnh câu, hiểu trọn vẹn ngữ nghĩa tinh tế.

Sơ đồ tinh chỉnh (Fine-tuning)



3. Thiết Kế Thử Nghiệm: 3 Miền Ngữ Liệu Thực Tế

Để kiểm chứng độ bền vững học thuật (**Generalization**), nhóm thử nghiệm song song trên 3 miền dữ liệu thực tế:

Đặc trưng	1. UIT-VSFC (Giáo dục)	2. E-Commerce (Thương mại)	3. Review-Phim (Điện ảnh IMDb)
Nguồn ngữ liệu	Ý kiến phản hồi SV ĐHQG TP.HCM	Đánh giá mua sắm sàn TMDT	Đánh giá phim điện ảnh IMDb
Quy mô mẫu	2,500 train / 600 test	2,500 train / 600 test	Tập kiểm thử chuẩn hóa
Phân bố nhãn	Cân bằng (300 Pos / 300 Neg)	Cân bằng (300 Pos / 300 Neg)	Cân bằng 2 lớp
Phong cách ngôn ngữ	Học thuật chuẩn mực, đúng chính tả	Ngôn ngữ MXH, tự do, cảm xúc	Nhận xét điện ảnh, phân tích kịch bản
Thách thức chính	Phủ định, góp ý lịch sự	Teencode (<i>sp, dc, ship, auth</i>), lỗi chính tả, mỉa mai	Cấu trúc tương phản dài (<i>khen diễn xuất nhưng chê kết phim</i>)

Ý nghĩa của thử nghiệm đa miền (Cross-Domain Evaluation)

Đánh giá độ nhạy cảm của các kiến trúc đối với hiện tượng dịch chuyển phân phối dữ liệu (**Distribution Shift**) và bùng nổ tỷ lệ từ ngoài từ điển (**OOV Explosion**).

Quy trình tiền xử lý 5 bước chuẩn hóa

- 1 **Chuẩn hóa Unicode NFC:** Khắc phục hiện tượng 2 mã nhị phân cho cùng một ký tự tiếng Việt.
- 2 **Lowercasing:** Đưa toàn bộ văn bản về dạng chữ thường.
- 3 **Làm sạch ký tự thừa:** Loại URL, thẻ HTML, ký tự điều khiển rác, giữ dấu ngắt câu cơ bản.
- 4 **Tách từ tiếng Việt (Pyvi):** Ghép từ phức bằng gạch dưới ("*nhiệt tình*" → "*nhiệt_tình*").
- 5 **Vector hóa & Padding:** Đưa câu về độ dài chuẩn `max_len = 64`.

Cấu hình siêu tham số huấn luyện

- **Phần cứng:** Apple Silicon GPU (Metal - MPS), RAM 16GB.
- **Word2Vec (Gensim):** $d = 100$, `window = 5`, `min_count = 1`, `architecture = CBOW`, `epochs = 30`.
- **BiLSTM + Self-Attention:**
 - $d_{embed} = 100$, $d_{hidden} = 128$ ($2 \times 128 = 256$)
 - $d_{attn} = 64$, `Dropout = 0.3`, `Batch size = 32`
 - Optimizer: Adam ($\eta = 0.001$, `weight decay = 1e - 4`)
- **PhoBERT Base v2 (Transformers):**
 - `Batch size = 16`, `Epochs = 4`, AdamW ($\eta = 2e - 5$)
 - Linear warmup & decay schedule

4. Bảng Số Liệu Đối Chuẩn 6 Mô Hình Trên Cả 3 Miền Dữ Liệu



TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH
Ho Chi Minh City University of Education

Số liệu đánh giá độc lập trên tập kiểm thử mỗi miền, khớp chính xác 100% với báo cáo chính thức:


STT	Kiến trúc Mô hình / Phương pháp	UIT-VSFC (Giáo dục)		E-Commerce (TMDT)		Review-Phim (IMDb)	
		Accuracy	F1-Score	Accuracy	F1-Score	Accuracy	F1-Score
1	TF-IDF + Logistic Regression (Baseline 1)	89.83%	89.80%	70.33%	69.65%	89.20%	89.54%
2	Average Word2Vec + LR (Baseline 2)	87.50%	87.49%	67.33%	66.80%	86.40%	86.82%
3	BiLSTM Scratch (Khởi tạo ngẫu nhiên)	89.17%	89.16%	69.17%	68.75%	88.10%	88.75%
4	BiLSTM Pretrained (Nạp sẵn Word2Vec)	91.00%	91.00%	67.17%	67.05%	90.80%	91.15%
5	BiLSTM + Self-Attention (Đề xuất XAI)	91.83%	91.83%	72.50%	72.40%	92.40%	92.80%
6	PhoBERT Base v2 (Transformer SOTA)	95.50%	95.50%	86.17%	86.16%	94.80%	95.10%

Đóng góp của Self-Attention

Tăng bất phá **+5.33%** trên E-Commerce (từ 67.17% lên 72.50%) nhờ khả năng lọc từ khóa mang cảm xúc trong câu nhiều.

Ưu thế vượt trội của PhoBERT

Đạt đỉnh **95.50%** trên UIT-VSFC và duy trì độ chính xác cao **86.17%** trên E-Commerce nhờ Tokenizer BPE và 12 tầng Attention.



Hình: Đôi chuẩn Accuracy & F1 giữa 6 mô hình trên các tập dữ liệu.


Phân tích mức sụt giảm miền (ΔAcc)

Khi chuyển sang TMDT MXH, các mô hình đều giảm do khác biệt phân phối:

- **TF-IDF**: Giảm 19.50% (89.83 $\rightarrow$ 70.33%)
- **Avg Word2Vec**: Giảm 20.17%
- **BiLSTM Scratch**: Giảm 20.00%
- **BiLSTM + Attention**: Giảm 19.33%
- **PhoBERT Base v2**: **Chỉ giảm 9.33%** (95.50 $\rightarrow$ 86.17%)

Kết luận kỹ thuật

PhoBERT bền vững nhất trước Domain Gap nhờ 20GB ngữ liệu tiền huấn luyện đa dạng.



Hình: Trọng số Attention phân bố trên câu phản hồi sinh viên.

Bảng chứng thực nghiệm về tính khả giải thích

- **Hư từ & thực thể** (*thầy, cô, bài, sinh_viên*): Trọng số nền rất nhỏ ($\alpha_t \in [0.02, 0.06]$).
- **Tính từ phân cực quyết định** (*nhật_tình, xuất_sắc, dễ_hiếu*): Nhận trọng số áp đảo ($\alpha_t \in [0.30, 0.48]$).


Giá trị ứng dụng thực tiễn

Giúp định vị ngay lập tức lý do một nhận xét bị đánh giá Tiêu cực hay Tích cực mà không cần đọc hết văn bản dài.

Tiến Hóa Không Gian Biểu Diễn Văn Bản Qua Chiều t-SNE




TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH
Ho Chi Minh City University of Education




(a) Average Word2Vec

Ranh giới mờ nhạt, điểm Pos/Neg hòa lẫn ở vùng giữa.



(b) BiLSTM Representation

Phân tách rõ hai nhánh đối xứng nhờ học chuỗi thời gian.



(c) PhoBERT Contextual

Hai cụm cô đặc tuyệt đối, khoảng cách phân cách cực rộng.

Nhận xét từ t-SNE

Hình ảnh chiều 2D minh chứng sắc nét lý do vì sao độ chính xác tăng dần từ 87.50% → 91.83% → 95.50%. Biểu diễn ngữ cảnh sâu của Transformer tạo ra siêu phẳng phân chia lớp tối ưu nhất.

1. Vì sao Avg Word2Vec kém hơn cả TF-IDF?

Hiện tượng: Avg W2V đạt 87.50% trong khi TF-IDF đạt 89.83% trên UIT-VSFC.

- **Mất trật tự từ tính giao hoán:** Phép cộng vector $\frac{1}{|D|} \sum v_w$ biến "thầy dạy không khó hiểu" và "thầy dạy khó hiểu không" thành cùng 1 vector!
- **Nghịch lý triệt tiêu phủ định:** Từ "không" xuất hiện cạnh cả từ tốt và xấu $\rightarrow$ vector ở tâm. Phép trung bình xem phủ định như sự **pha loãng** chứ không thể **đảo chiều** vector.
- **Ưu thế của TF-IDF:** Giữ nguyên từng từ độc lập, cho phép gán trọng số âm lớn cho từ phủ định.

2. Giá trị Transfer Learning của Word2Vec

Hiện tượng: BiLSTM Pretrained tăng +1.83% so với BiLSTM Scratch (89.17% $\rightarrow$ 91.00%).

- **BiLSTM Scratch:** Tăng nhúng ngẫu nhiên; 2,500 mẫu không đủ học hình học cho các từ hiếm.
- **BiLSTM Pretrained:** Được trang bị sẵn cấu trúc ngữ nghĩa từ kho lớn, mạng tập trung toàn lực vào **học lan truyền ngữ cảnh theo chuỗi thời gian**.
- Giúp mô hình hội tụ nhanh hơn gấp 2x và hạn chế hiện tượng overfitting.

3. Cơ chế nào giúp Attention bứt phá?

Tăng vượt bậc **+5.33%** trên E-Commerce (67.17% → 72.50%):

- **Xóa bỏ Information Bottleneck:** Không ép câu qua h_T mà tạo đường tắt trực tiếp từ mọi từ đến bộ phân loại ($v_D = \sum \alpha_t h_t$).
- **Soft Feature Selection:** Tự động hạ thấp trọng số hư từ và khuếch đại tính từ đối lập (rất quan trọng trong câu có cấu trúc tương phản: "*Giao hàng nhanh nhưng đồ quá xấu*").

4. Nguyên nhân sụt giảm khi sang E-Commerce?

Tất cả mô hình từ điển cố định đều sụt giảm 20% do:

- **Bùng nổ Out-of-Vocabulary (OOV):** Teencode (*sp, dc, ship, auth, fake*), viết tắt, sai chính tả tùy tiện.
- **Ngôn ngữ châm biếm / Sarcasm:** Dùng từ tích cực bề mặt để chê bai chất lượng.
- **PhoBERT bền bỉ nhất ($\Delta = 9.33\%$):** Nhờ cơ chế tách subwords BPE bền bỉ từ lạ thành đơn vị con.

Nhóm tiến hành mổ xẻ các ca sai sót điển hình để xác định giới hạn kỹ thuật của các kiến trúc:

Trường hợp 1: Cấu trúc câu tương phản đảo hướng ngữ nghĩa

- **Câu kiểm thử:** "Giao hàng hơi lâu nhưng chất lượng áo thì đỉnh chóp." → **Thực tế: TÍCH CỰC.**
- **BiLSTM dự đoán: Tiêu cực.**
- **Nguyên nhân:** Từ lỏng "đỉnh chóp" bị OOV; mạng đọc từ trái sang phải gặp "hơi lâu" gây lệch trạng thái ẩn ban đầu, chưa học được quy luật liên từ "nhưng" đảo hướng ngữ nghĩa.

Trường hợp 2: Ngôn ngữ mỉa mai / châm biếm (Sarcasm)

- **Câu kiểm thử:** "Shop phục vụ quá nhiệt tình, nhấn tin 3 ngày mới thêm rep." → **Thực tế: TIÊU CỰC.**
- **Cả BiLSTM+Attention và PhoBERT đều dự đoán: Tích cực (Độ tin cậy > 90%).**
- **Nguyên nhân:** Thiếu tri thức đời thực (World Knowledge) rằng "3 ngày" là quá trễ. Cơ chế Attention bị đánh lừa bởi từ cực tính mạnh "quá nhiệt tình".

5. Hệ Thống Ứng Dụng Thời Gian Thực (Demo Application)



TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH
Ho Chi Minh City University of Education


Kiến trúc Inference Engine đa nhiệm

Xây dựng hệ thống web demo hoàn chỉnh tích hợp:


- **3 Miền dữ liệu:** UIT-VSFC, E-Commerce, Review-Phim IMDb.
- **6 Kiến trúc mô hình:** Chạy song song và đo đặc độ trễ suy luận (*Latency*) thời gian thực.
- **Module XAI trực quan:** Sinh bản đồ nhiệt Attention Heatmap tương tác cho từng từ vựng.
- **Công nghệ:** Streamlit + PyTorch + Transformers + Pyvi.

Độ trễ suy luận thực tế (Latency)

TF-IDF / W2V: $\approx 5\text{ms}$ | BiLSTM: $\approx 15\text{ms}$ | PhoBERT: $\approx 65\text{ms}$.



Hình: Giao diện so sánh đồng thời 6 mô hình thời gian thực.



Hình: Bản đồ nhiệt Attention Heatmap trực quan hóa trên Web Demo.

Tính năng nổi bật của Web Demo

- **Phân tích từ khóa đóng góp:** Tự động tô màu các từ có trọng số α_t cao theo dải màu trực quan.
- **Bộ mẫu câu phong phú:** Khen ngợi, phàn nàn, phủ định phức tạp, teencode mua sắm, review phim.
- **So sánh đối đầu:** Kiểm chứng tức thì trường hợp mô hình nào thắng, mô hình nào thua.

Đường dẫn trải nghiệm

Khởi chạy tại máy qua script:

```
cd Bai_tap_giua_ky && ./run_app.sh
```

6. Kết Luận Nghiên Cứu



Thành quả nghiên cứu chính

- ❶ **Làm chủ chuỗi công nghệ:** Từ Word2Vec tĩnh đến BiLSTM và Transformer SOTA PhoBERT.
- ❷ **Chứng minh thành công Self-Attention:** Bứt phá độ chính xác (+5.33% trên E-Commerce), mở toang hộp đen với trọng số chú ý giải thích được.
- ❸ **Thực nghiệm đa miền chặt chẽ:** Chỉ ra Domain Gap và chứng minh sự bền bỉ của Tokenizer BPE.
- ❹ **Đóng gói sản phẩm hoàn chỉnh:** Web Demo trực quan, sẵn sàng kiểm chứng thực tế.

Hướng phát triển tiếp theo

- **Chuẩn hóa Teencode & Tiếng lóng:** Tích hợp module chuẩn hóa từ viết tắt tự động.
- **Xử lý Châm biếm (Sarcasm):** Bổ sung tri thức đồ thị (Knowledge Graph) hoặc đa phương thức.
- **Mô hình siêu nhẹ (Distillation):** Tinh gọn PhoBERT (DistilPhoBERT, TinyBERT) để đạt độ trễ < 10ms trên thiết bị biên.



ĐẠI HỌC
TP. HỒ CHÍ MINH

CHÂN THÀNH CẢM ƠN THẦY VÀ CÁC BẠN

Giảng viên hướng dẫn: PGS.TS. LÊ ANH CƯỜNG

Nhóm 3: Trần Gia Huy • Đỗ Minh Khánh Ngân • Nguyễn Tấn Phát